

Introduction aux Séries Temporelles

mathématiques et apprentissage automatique

Tawfik Masrour
ENSAM - IATD

Année Universitaire 2024-2025

1 Introduction aux séries temporelles

1.1 Définition mathématique d'une série temporelle

Une série temporelle est une suite de données $\{y_t\}$, où y_t représente la valeur observée à un temps t . Le temps t peut être discret (par exemple, $t = 1, 2, 3, \dots$) ou continu.

1.1.1 Forme générale

La forme générale d'une série temporelle est donnée par:

$$y_t = f(t) + \epsilon_t$$

où:

- $f(t)$ est une fonction déterministe qui décrit la structure de la série (tendance, saisonnalité, etc.).
- ϵ_t est une composante aléatoire (bruit) qui suit généralement une distribution de moyenne nulle.

1.2 Définitions des composantes

1.2.1 Tendance (Trend)

La tendance T_t représente le mouvement à long terme de la série temporelle. Elle capture les changements graduels et persistants dans les données. Mathématiquement, la tendance peut être modélisée comme une fonction du temps t . Par exemple:

- **Tendance linéaire:**

$$T_t = \beta_0 + \beta_1 t$$

où β_0 est l'ordonnée à l'origine et β_1 est la pente.

- **Tendance quadratique:**

$$T_t = \beta_0 + \beta_1 t + \beta_2 t^2$$

où β_2 capture l'accélération ou la décélération de la tendance.

- **Tendance exponentielle:**

$$T_t = \beta_0 e^{\beta_1 t}$$

où β_1 détermine le taux de croissance ou de décroissance.

1.2.2 Saisonnalité (Seasonality)

La saisonnalité S_t représente des variations périodiques qui se répètent à intervalles réguliers. Elle est souvent liée à des cycles naturels (par exemple, les saisons, les jours de la semaine, les mois de l'année). Mathématiquement, la saisonnalité peut être modélisée comme une fonction périodique du temps t . Par exemple:

- **Saisonnalité sinusoïdale:**

$$S_t = A \sin\left(\frac{2\pi t}{P} + \phi\right)$$

où:

- A est l'amplitude des variations saisonnières.
- P est la période (par exemple, $P = 12$ pour une saisonnalité annuelle avec des données mensuelles).
- ϕ est la phase (décalage temporel).

- **Saisonnalité avec indicateurs:**

$$S_t = \sum_{i=1}^k \alpha_i D_i(t)$$

où $D_i(t)$ est un indicateur binaire pour la saison i (par exemple, $D_i(t) = 1$ si t correspond à la saison i , sinon 0).

1.2.3 Bruit (Noise)

Le bruit ϵ_t représente les variations aléatoires et imprévisibles dans la série temporelle. Il est souvent modélisé comme un processus stochastique stationnaire, par exemple un bruit blanc gaussien:

$$\epsilon_t \sim \mathcal{N}(0, \sigma^2)$$

où σ^2 est la variance du bruit. Le bruit capture les fluctuations qui ne peuvent pas être expliquées par la tendance ou la saisonnalité.

1.3 Exemples concrets


Voici quelques exemples de séries temporelles pour illustrer ces définitions:

Exemple 1: Ventes mensuelles d'un produit Considérons les ventes mensuelles d'un produit sur plusieurs années. La série temporelle $\{y_t\}$ peut être modélisée comme:

$$y_t = \underbrace{\beta_0 + \beta_1 t}_{\text{Tendance}} + \underbrace{A \sin\left(\frac{2\pi t}{12}\right)}_{\text{Saisonnalité}} + \underbrace{\epsilon_t}_{\text{Bruit}}$$

où:

- $\beta_0 + \beta_1 t$ représente une tendance linéaire (par exemple, une augmentation constante des ventes).
- $A \sin\left(\frac{2\pi t}{12}\right)$ modélise une saisonnalité annuelle (période de 12 mois).
- ϵ_t est un bruit gaussien de moyenne nulle et de variance σ^2 .



Exemple 2: Température quotidienne La température quotidienne dans une ville peut être modélisée comme:


$$y_t = \underbrace{\beta_0 + \beta_1 t + \beta_2 t^2}_{\text{Tendance quadratique}} + \underbrace{A \cos\left(\frac{2\pi t}{365}\right)}_{\text{Saisonnalité annuelle}} + \underbrace{\epsilon_t}_{\text{Bruit}}$$

où:

- $\beta_0 + \beta_1 t + \beta_2 t^2$ représente une tendance quadratique (par exemple, un réchauffement climatique accéléré).

- $A \cos\left(\frac{2\pi t}{365}\right)$ modélise une saisonnalité annuelle due aux variations saisonnières.
- ϵ_t est un bruit gaussien représentant les fluctuations quotidiennes.


Dans un premier temps, on peut tracer directement ce modèle pour observer que le point haut (été) a lieu quand la partie cosinus vaut $+A$, et le point bas (hiver) quand elle vaut $-A$.



Toutefois, afin de caler le minimum en hiver (par exemple, en janvier) et le maximum en été (en juillet) pour un climat de l'hémisphère nord, on introduit un **décalage de phase** ϕ tel que:

$$y_t = \beta_0 + \beta_1 t + \beta_2 t^2 + A \cos\left(\frac{2\pi t}{365} + \phi\right) + \epsilon_t.$$

En choisissant $\phi = \pi$, on décale le minimum de la fonction cosinus au début de l'année (pour un $t = 0$ correspondant au 1^{er} janvier), rendant ainsi la courbe plus réaliste au regard des cycles saisonniers habituels de l'hémisphère nord.



Exemple 3: Cours boursiers Pour modéliser le cours d'une action boursière, un simple modèle linéaire ($y_t = \beta_0 + \beta_1 t + \epsilon_t$) est souvent trop simpliste.

En effet, les marchés financiers sont souvent décrits par une *marche aléatoire*, éventuellement assortie d'une *dérive* (drift) pour refléter une croissance ou décroissance moyenne.

Une formulation "raisonnable" repose sur la modélisation de la *variation quotidienne* Δy_t comme un processus autorégressif (AR) d'ordre 1, avec drift:

$$\Delta y_t = y_t - y_{t-1} = \alpha + \phi \Delta y_{t-1} + \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, \sigma^2),$$

et


$$y_t = y_{t-1} + \Delta y_t, \quad y_0 = \text{cours initial}.$$

Dans ce modèle:

- α représente la *dérive* (ou drift), c'est-à-dire la croissance moyenne quotidienne (si elle est positive).
- ϕ est le *coefficient d'autorégression*, mesurant la dépendance entre la variation d'aujourd'hui Δy_t et celle d'hier Δy_{t-1} .
- ϵ_t est un *bruit gaussien* d'espérance nulle et de variance σ^2 .

Ainsi, on s'éloigne de la stricte hypothèse d'une tendance linéaire pour adopter un comportement plus proche de ce que l'on observe en pratique, où les cours évoluent par *accumulation de petites variations aléatoires*.

On suppose, en général, le comportement *sans saisonnalité*, car les cours de bourse ne présentent en général pas de cycle saisonnier marqué (comme les températures ou la consommation de biens soumis aux saisons), même s'il peut exister des **effets de calendrier** ou des **effets de fin d'année** plus subtils.



Complément théorique: marches aléatoires

Pour aller plus loin sur la notion de *marche aléatoire* (*random walk*), voici quelques rappels théoriques et remarques pratiques:

Marche aléatoire simple. On considère une série temporelle $\{X_t\}$ définie par:

$$X_t = X_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2),$$

avec X_0 donné. Cette suite n'est pas stationnaire, car $\text{Var}(X_t) = t\sigma^2$ croît linéairement avec t . En revanche, la suite des différences $\Delta X_t = X_t - X_{t-1}$ est stationnaire (variance et espérance constantes) et correspond ici au bruit ε_t .

Marche aléatoire avec drift. On peut ajouter une *dérive* (ou *drift*) μ pour refléter une croissance ou décroissance à long terme:

$$X_t = X_{t-1} + \mu + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2).$$

On obtient alors $\mathbb{E}[X_t] = X_0 + t\mu$, tandis que $\text{Var}(X_t)$ reste $t\sigma^2$.

AR(1) sur les variations. Une autre façon d'enrichir le modèle consiste à autoriser une *autorégression* sur la variation elle-même :

$$\Delta X_t = \alpha + \phi \Delta X_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2).$$

Alors, ΔX_t peut présenter une *mémoire* (dépendance avec ΔX_{t-1}). Si $|\phi| < 1$, $\{\Delta X_t\}$ reste stationnaire, et $\{X_t\}$ est alors une *marche aléatoire* (avec dérive) dont les variations ont une composante AR(1).

Application en finance. En pratique, la Random Walk Hypothesis est souvent évoquée pour décrire le *caractère imprévisible* des cours boursiers dans des marchés (plus ou moins) efficients. Sous cette hypothèse, toute information est immédiatement intégrée


au prix, rendant les ε_t *inobservables* et aléatoires. Divers modèles plus avancés (notamment les *processus ARCH/GARCH* pour la volatilité, ou les *modèles ARIMA* et les *marches browniennes géométriques*) affinent cette description en tenant compte de l'évolution de la variance ou des effets de long terme (*Nous y reviendrons dans les Labs*).

Exemple: le “promeneur ébourdi” (random walk 1D). Considérons un marcheur partant de l'origine, et effectuant des pas ± 1 (au choix équiprobable) à chaque instant $t = 1, 2, \dots, n$. Sa position s'écrit

$$X_t = \sum_{k=1}^t S_k, \quad S_k \in \{+1, -1\}, \quad \mathbb{P}(S_k = +1) = \mathbb{P}(S_k = -1) = 0.5.$$

On obtient alors une *marche aléatoire simple*, dont l'espérance reste constante $\mathbb{E}[X_t] = 0$, mais dont la variance $\text{Var}(X_t) = t$ croît avec le temps.

L'exemple suivant illustre la génération de cette trajectoire (pendant 200 pas) et son affichage:




Cet exemple illustre la croissance de la dispersion autour de zéro, et constitue un cas élémentaire de *random walk*, à la base de nombreuses applications en finance, physique, et mathématiques.

Exemple 4: Consommation électrique mensuelle. La consommation électrique d'un foyer peut être modélisée par la formule:

$$y_t = \underbrace{\beta_0 + \beta_1 t}_{\text{Tendance linéaire}} + \underbrace{A \sin\left(\frac{2\pi t}{12}\right) + B \cos\left(\frac{2\pi t}{12}\right)}_{\text{Saisonnalité annuelle}} + \underbrace{\varepsilon_t}_{\text{Bruit}},$$

où ε_t est un bruit gaussien d'espérance nulle et d'écart-type σ .

Dans l'application ci-dessous, nous générons des données mensuelles pour 36 mois, avec une tendance ($\beta_0 = 200$, $\beta_1 = 1.5$), et un cycle annuel déterminé par $(A, B) = (30, 20)$:



La figure obtenue montre clairement la *tendance croissante*, ainsi que la *variabilité saisonnière* sur 12 mois.

2 Propriétés statistiques des séries temporelles

2.1 Notions fondamentales: Espérance et Variance

Lorsqu'on étudie une série temporelle $\{y_t\}$, il est crucial de comprendre deux mesures statistiques fondamentales: l'**espérance** et la **variance**, qui permettent de caractériser la tendance centrale et la dispersion des données.

2.1.1 Espérance (Moyenne)

L'espérance mathématique est une mesure fondamentale en analyse des séries temporelles. Elle représente la valeur moyenne autour de laquelle les observations fluctuent.

Cas d'une variable aléatoire discrète Si Y est une variable aléatoire discrète prenant des valeurs y_i avec une probabilité associée $p(y_i)$, alors son espérance est définie par:

$$\mathbb{E}[Y] = \sum_i y_i p(y_i). \quad (1)$$

Cette expression correspond à une moyenne pondérée des valeurs possibles de Y , où chaque valeur est pondérée par sa probabilité d'occurrence.

Cas d'une variable aléatoire continue Si Y est une variable aléatoire continue avec une fonction de densité de probabilité $f(y)$, alors l'espérance est définie par:

$$\mathbb{E}[Y] = \int_{-\infty}^{+\infty} y f(y) dy. \quad (2)$$

Cette expression intègre toutes les valeurs possibles de Y , pondérées par leur densité de probabilité.

Cas d'une série temporelle Pour une série temporelle $\{y_t\}$, l'espérance à un instant t est définie comme:

$$\mathbb{E}[y_t] = \mu_t. \quad (3)$$

Dans le cas d'une série stationnaire, l'espérance est constante dans le temps:

$$\mathbb{E}[y_t] = \mu, \quad \forall t. \quad (4)$$

Estimation empirique de l'espérance Si l'on dispose d'un échantillon fini de N observations $\{y_1, y_2, \dots, y_N\}$, l'espérance peut être estimée par la moyenne empirique:

$$\hat{\mu} = \frac{1}{N} \sum_{t=1}^N y_t. \quad (5)$$

Cette estimation repose sur l'hypothèse que chaque observation y_t a la même probabilité d'occurrence.

Espérance conditionnelle Dans un cadre plus avancé, on peut étudier l'espérance conditionnelle, qui correspond à l'espérance de y_t sachant une information passée $\mathcal{F}_{t-1}$:

$$\mathbb{E}[y_t | \mathcal{F}_{t-1}]. \quad (6)$$

Cette notion est essentielle en prévision des séries temporelles.

2.1.2 Variance

La **variance** est une mesure statistique qui quantifie la **dispersion** des valeurs autour de leur moyenne. Elle permet d'évaluer l'ampleur des fluctuations d'une variable aléatoire ou d'une série temporelle.

Cas d'une variable aléatoire discrète Si Y est une variable aléatoire discrète prenant des valeurs y_i avec une probabilité associée $p(y_i)$, alors sa variance est définie par:

$$\text{Var}(Y) = \mathbb{E}[(Y - \mathbb{E}[Y])^2] = \sum_i (y_i - \mu)^2 p(y_i), \quad (7)$$

où $\mu = \mathbb{E}[Y]$ représente l'espérance de Y .

Cas d'une variable aléatoire continue Si Y est une variable aléatoire continue avec une fonction de densité de probabilité $f(y)$, alors la variance est définie par:

$$\text{Var}(Y) = \int_{-\infty}^{+\infty} (y - \mu)^2 f(y) dy. \quad (8)$$

Cette expression intègre toutes les valeurs possibles de Y , pondérées par leur densité de probabilité.

Cas d'une série temporelle Pour une série temporelle $\{y_t\}$, la variance à un instant t est donnée par:

$$\text{Var}(y_t) = \mathbb{E}[(y_t - \mu_t)^2]. \quad (9)$$

Dans le cas d'une **série stationnaire**, la variance est constante dans le temps:

$$\text{Var}(y_t) = \sigma^2, \quad \forall t. \quad (10)$$

Décomposition alternative de la variance À partir des propriétés de l'espérance, on peut également exprimer la variance comme:

$$\text{Var}(y_t) = \mathbb{E}[y_t^2] - (\mathbb{E}[y_t])^2. \quad (11)$$

Cette formulation permet de calculer la variance à partir des moments d'ordre 1 et 2.

Estimation empirique de la variance Si l'on dispose d'un échantillon fini de N observations $\{y_1, y_2, \dots, y_N\}$, la variance peut être estimée par la variance empirique:

$$\hat{\sigma}^2 = \frac{1}{N} \sum_{t=1}^N (y_t - \hat{\mu})^2, \quad (12)$$

où $\hat{\mu}$ est la moyenne empirique.

Dans le cas d'un estimateur sans biais (en tenant compte des degrés de liberté), on utilise la correction de Bessel:

$$\hat{\sigma}^2 = \frac{1}{N-1} \sum_{t=1}^N (y_t - \hat{\mu})^2. \quad (13)$$

Variance conditionnelle Dans le contexte des séries temporelles, on s'intéresse souvent à la variance conditionnelle, qui représente l'incertitude sur y_t sachant une information passée $\mathcal{F}_{t-1}$:

$$\text{Var}(y_t | \mathcal{F}_{t-1}). \quad (14)$$

Cette notion est fondamentale dans les modèles ARCH/GARCH qui modélisent l'évolution de la volatilité au fil du temps.

2.1.3 Exemple 1: Espérance et Variance d'un lancer de dé équilibré

Considérons une variable aléatoire X qui représente le résultat du lancer d'un dé équilibré à six faces. Chaque face x_i prend une valeur entre 1 et 6, avec une probabilité égale de $\frac{1}{6}$.




Figure 1: Histogramme de la distribution des valeurs d'un dé équilibré.

Calcul de l'Espérance L'espérance mathématique de X est donnée par:

$$\mathbb{E}[X] = \sum_{i=1}^6 x_i P(x_i). \quad (15)$$

Substituons les valeurs:

$$\mathbb{E}[X] = 1 \times \frac{1}{6} + 2 \times \frac{1}{6} + 3 \times \frac{1}{6} + 4 \times \frac{1}{6} + 5 \times \frac{1}{6} + 6 \times \frac{1}{6} = \frac{21}{6} = 3.5.$$

L'espérance $\mathbb{E}[X] = 3.5$ signifie que, sur un grand nombre de lancers, la moyenne des résultats tendra vers cette valeur.

Calcul de la Variance La variance mesure la dispersion autour de leur moyenne:

$$Var(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2. \quad (16)$$

Calculons $\mathbb{E}[X^2]$:

$$\mathbb{E}[X^2] = 1^2 \times \frac{1}{6} + 2^2 \times \frac{1}{6} + 3^2 \times \frac{1}{6} + 4^2 \times \frac{1}{6} + 5^2 \times \frac{1}{6} + 6^2 \times \frac{1}{6} = \frac{91}{6} \approx 15.1667.$$

Ce qui donne:

$$Var(X) = 15.1667 - (3.5)^2 = 2.9167.$$

Ainsi, la variance de X est 2.9167, ce qui indique que les valeurs sont modérément dispersées autour de la moyenne.

Interprétation du Graphique La figure 1 illustre la distribution des résultats d'un dé équilibré, où chaque face a une probabilité égale d'apparition. Cette distribution uniforme permet d'analyser trois mesures essentielles:

- **L'espérance** $\mathbb{E}[X] = 3.50$ représente la valeur moyenne théorique attendue après un grand nombre de lancers. Bien qu'elle ne soit pas une valeur réalisable (un dé ne donne que des entiers), elle traduit le centre de gravité de la distribution.
- **La variance** $\text{Var}(X) = 2.92$ mesure l'écart des valeurs autour de la moyenne, quantifiant la dispersion des résultats.
- **L'écart-type** $\sigma(X) = 1.71$, en tant que racine carrée de la variance, exprime cette dispersion dans l'unité d'origine des données, facilitant ainsi son interprétation.

Ces résultats sont cohérents: bien que chaque valeur soit obtenue avec la même probabilité, leurs écarts à la moyenne génèrent une dispersion mesurable.

Résumé des Mesures de Dispersion Les trois principales mesures statistiques utilisées pour caractériser une série de données sont:

- **Espérance** $\mathbb{E}[X]$: moyenne pondérée par les probabilités, représentant le point d'équilibre des observations.
- **Variance** $\text{Var}(X)$: moyenne des carrés des écarts à l'espérance, mettant en évidence l'ampleur de la dispersion.
- **Écart-type** $\sigma(X)$: racine carrée de la variance, permettant une interprétation plus intuitive de la dispersion.

Dans notre exemple:

- L'espérance $\mathbb{E}[X] = 3.50$ indique la moyenne des valeurs obtenues sur un grand nombre de lancers.
- L'écart-type $\sigma(X) = 1.71$ signifie que la majorité des valeurs sont comprises entre 1.79 et 5.21.
- La variance $\text{Var}(X) = 2.92$ traduit l'étendue de la dispersion des valeurs autour de la moyenne.

La règle empirique (68-95-99.7) Cette règle permet d'estimer la répartition des observations autour de l'espérance dans le cas d'une distribution normale:

- 68% des valeurs se situent dans $[\mathbb{E}[X] - \sigma(X), \mathbb{E}[X] + \sigma(X)]$.
- 95% des valeurs se situent dans $[\mathbb{E}[X] - 2\sigma(X), \mathbb{E}[X] + 2\sigma(X)]$.
- 99.7% des valeurs se situent dans $[\mathbb{E}[X] - 3\sigma(X), \mathbb{E}[X] + 3\sigma(X)]$.

Application à notre exemple: Bien que la distribution d'un dé ne soit pas strictement normale, nous pouvons approximativement estimer que:

- 68% des valeurs devraient se situer dans $[1.79, 5.21]$.
- 95% des valeurs devraient se situer dans $[0.08, 6.92]$, mais la borne inférieure n'a pas de sens ici puisque la valeur minimale réalisable est 1.

Conclusion L'espérance représente la tendance centrale des observations, tandis que la variance et l'écart-type décrivent leur dispersion. La règle empirique est un outil utile pour interpréter ces notions dans le cas de distributions normales.

2.1.4 Exemple 2: Espérance et Variance d'une variable aléatoire continue (Loi uniforme)

Considérons une variable aléatoire X qui suit une **loi uniforme continue**¹ sur l'intervalle $[a, b]$, c'est-à-dire que sa densité de probabilité est constante sur cet intervalle:

$$f(x) = \frac{1}{b-a}, \quad \text{pour } x \in [a, b]. \quad (17)$$

Dans notre exemple, nous choisissons $a = 2$ et $b = 8$, ce qui signifie que X prend ses valeurs entre 2 et 8 avec une probabilité égale.

Calcul de l'Espérance L'espérance d'une variable suivant une loi uniforme $U(a, b)$ est donnée par:

$$\mathbb{E}[X] = \frac{a+b}{2}. \quad (18)$$

En remplaçant par nos valeurs:

$$\mathbb{E}[X] = \frac{2+8}{2} = 5.$$

Ainsi, la moyenne théorique des valeurs prises par X est 5, ce qui correspond au centre de l'intervalle.

Calcul de la Variance La variance d'une loi uniforme $U(a, b)$ est donnée par:

$$\text{Var}(X) = \frac{(b-a)^2}{12}. \quad (19)$$

En remplaçant:

$$\text{Var}(X) = \frac{(8-2)^2}{12} = \frac{36}{12} = 3.$$

L'écart-type est donc:

$$\sigma(X) = \sqrt{\text{Var}(X)} = \sqrt{3} \approx 1.73. \quad (20)$$

¹**Loi uniforme continue:**

- **Définition:** La loi uniforme continue est une distribution de probabilité pour des valeurs continues dans un intervalle donné $[a, b]$, où toutes les valeurs de cet intervalle sont également probables.
- **Nature:** La loi uniforme est applicable uniquement pour des variables continues.
- **Exemple typique:** Une variable aléatoire X uniformément répartie sur $[2, 8]$ a une densité de probabilité constante donnée par:

$$f(x) = \frac{1}{b-a} = \frac{1}{8-2} = \frac{1}{6}, \quad \text{pour } x \in [2, 8].$$

Dans ce cas, la probabilité d'observer exactement une valeur précise, comme $X = 3.5$, est nulle, car les probabilités associées à des valeurs individuelles dans un intervalle continu sont infinitésimales.

	Bin	Densité	Nombre d'observations
0	[2.00, 2.20]	0.161500	323
1	[2.20, 2.40]	0.176100	352
2	[2.40, 2.60]	0.178100	356
3	[2.60, 2.80]	0.175600	351
4	[2.80, 3.00]	0.160500	321
5	[3.00, 3.20]	0.170000	340
6	[3.20, 3.40]	0.164000	328
7	[3.40, 3.60]	0.172100	344
8	[3.60, 3.80]	0.168000	336
9	[3.80, 4.00]	0.161500	323
10	[4.00, 4.20]	0.170000	340
11	[4.20, 4.40]	0.171600	343
12	[4.40, 4.60]	0.179100	358
13	[4.60, 4.80]	0.170000	340
14	[4.80, 5.00]	0.160000	320
15	[5.00, 5.20]	0.174600	349
16	[5.20, 5.40]	0.171100	342
17	[5.40, 5.60]	0.171100	342
18	[5.60, 5.80]	0.160500	321
19	[5.80, 6.00]	0.168000	336
20	[6.00, 6.20]	0.174100	348
21	[6.20, 6.40]	0.161000	322
22	[6.40, 6.60]	0.154000	308
23	[6.60, 6.80]	0.146000	292
24	[6.80, 7.00]	0.183600	367
25	[7.00, 7.20]	0.153500	307
26	[7.20, 7.40]	0.164000	328
27	[7.40, 7.60]	0.149000	298
28	[7.60, 7.80]	0.178100	356
29	[7.80, 8.00]	0.154500	309

Figure 2: Les bins [2, 8].

Interprétation du Graphique La figure 3 illustre la densité de probabilité d'une loi uniforme entre 2 et 8. Les principales caractéristiques sont:

- **L'espérance** $\mathbb{E}[X] = 5$ est située au centre de l'intervalle [2, 8].
- **La variance** $\text{Var}(X) = 3$ mesure la dispersion des valeurs autour de cette moyenne.
- **L'écart-type** $\sigma(X) \approx 1.73$ indique que la plupart des valeurs sont concentrées entre 5 ± 1.73 , soit entre 3.27 et 6.73.

Ces résultats sont cohérents avec l'idée que dans une loi uniforme, toutes les valeurs ont la même probabilité d'apparition, mais elles restent concentrées autour de la moyenne.

Résumé des Mesures de Dispersion Pour une loi uniforme $U(a, b)$, les formules générales sont:

- **Espérance:** $\mathbb{E}[X] = \frac{a+b}{2}$.
- **Variance:** $\text{Var}(X) = \frac{(b-a)^2}{12}$.
- **Écart-type:** $\sigma(X) = \sqrt{\text{Var}(X)}$.




Figure 3: Densité de probabilité d'une loi uniforme sur l'intervalle $[2, 8]$.

Dans notre exemple:

- L'espérance $E[X] = 5$ est au centre de l'intervalle $[2, 8]$.
- L'écart-type $\sigma(X) \approx 1.73$ montre que la majorité des valeurs sont comprises entre 3.27 et 6.73.
- La variance $Var(X) = 3$ indique une dispersion modérée autour de la moyenne.

Comparaison avec la règle empirique (68-95-99.7) Bien que la loi uniforme ne soit pas normale, nous pouvons tout de même examiner comment les valeurs se répartissent autour de l'espérance:

- Environ 68% des valeurs se situent dans $[E[X] - \sigma(X), E[X] + \sigma(X)] = [3.27, 6.73]$.
- Environ 95% des valeurs se situent dans $[E[X] - 2\sigma(X), E[X] + 2\sigma(X)] = [1.54, 8.46]$.

Toutefois, la borne supérieure est limitée à 8, ce qui signifie que toute valeur supérieure ne peut exister.

Conclusion Dans une loi uniforme, toutes les valeurs de l'intervalle sont équiprobables, et la moyenne est située au centre. La variance et l'écart-type mesurent la dispersion des valeurs, qui est plus faible que dans d'autres distributions plus étalées comme la loi normale.

2.1.5 Exemple 3: Loi Normale $\mathcal{N}(3, 2)$

Considérons une variable aléatoire X suivant une **loi normale** $\mathcal{N}(\mu, \sigma^2)$, où $\mu = 3$ représente la moyenne et $\sigma^2 = 2$ la variance. Cela signifie que X est centrée autour de 3 avec une dispersion définie par $\sigma = \sqrt{2}$.

Densité de Probabilité La densité de probabilité d'une variable aléatoire suivant une loi normale $\mathcal{N}(\mu, \sigma^2)$ est donnée par:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}. \quad (21)$$

Dans notre exemple, avec $\mu = 3$ et $\sigma^2 = 2$, cela devient:

$$f(x) = \frac{1}{\sqrt{4\pi}} \exp\left(-\frac{(x-3)^2}{4}\right). \quad (22)$$

Calculs de l'Espérance et de la Variance Pour une loi normale quelconque $\mathcal{N}(\mu, \sigma^2)$:

- L'espérance est donnée par:

$$\mathbb{E}[X] = \mu. \quad (23)$$

- La variance est donnée par:

$$\text{Var}(X) = \sigma^2. \quad (24)$$

Dans notre exemple, nous avons $\mathbb{E}[X] = 3$ et $\text{Var}(X) = 2$, avec $\sigma(X) = \sqrt{2} \approx 1.41$.

Simulation et Visualisation Nous générons un échantillon de $n = 10,000$ observations suivant $\mathcal{N}(3, 2)$ et traçons l'histogramme des valeurs avec une superposition de la densité théorique. Les résultats sont illustrés dans la figure 4.

Calcul et Interprétation des Bins Dans notre histogramme, chaque bin représente un intervalle de valeurs de X . La hauteur de chaque bin est calculée pour approximer la densité de probabilité empirique à partir des données simulées. Les intervalles des bins et leurs densités respectent la relation suivante:

$$\text{Densité} = \frac{\text{Nombre d'observations dans le bin}}{\text{Largeur du bin} \times \text{Taille totale de l'échantillon}}. \quad (25)$$




Figure 4: Histogramme des valeurs simulées de $\mathcal{N}(3, 2)$ avec densité théorique.

Par exemple², pour un bin donné $[2.5, 3.0]$ avec 150 observations:

$$\begin{aligned} \text{Densité} &= \frac{150}{(3.0 - 2.5) \times 10,000} \\ &= \frac{150}{5000} = 0.03. \end{aligned}$$

²Dans le cas de la loi normale, les **bins** (ou intervalles) d'un histogramme sont définis pour regrouper les observations en fonction de leur valeur. Leur choix repose sur des critères mathématiques visant à équilibrer la précision et la lisibilité. Voici les principales méthodes utilisées :

- **Méthode de Sturges** : Le nombre de bins k est donné par $k = \lceil \log_2(n) + 1 \rceil$, où n est le nombre d'échantillons. Cette méthode est adaptée pour de petits échantillons, mais elle peut sous-estimer k pour des échantillons volumineux.
- **Méthode de Freedman-Diaconis** : Cette méthode utilise l'écart interquartile (IQR) pour ajuster la largeur des bins w , définie par $w = \frac{2 \times IQR}{\sqrt[3]{n}}$. Le nombre de bins est alors $k = \frac{\text{étendue des données}}{w}$. Elle est robuste face aux distributions asymétriques.
- **Méthode de Scott** : Basée sur l'écart-type σ , la largeur des bins est donnée par $w = \frac{3.5 \times \sigma}{\sqrt[3]{n}}$, et le nombre de bins est $k = \frac{\text{étendue des données}}{w}$. Cette méthode est bien adaptée aux distributions normales.

Dans notre exemple, pour un échantillon de taille $n = 10,000$:

- Avec la méthode de Sturges : $k = \lceil \log_2(10,000) + 1 \rceil = 15$ bins.
- Avec la méthode de Freedman-Diaconis (supposant $IQR \approx 4$) : $w = \frac{2 \times 4}{\sqrt[3]{10,000}} \approx 0.8$, donc $k = \frac{12}{0.8} = 15$ bins.
- Avec la méthode de Scott (supposant $\sigma = \sqrt{2} \approx 1.414$) : $w = \frac{3.5 \times 1.414}{\sqrt[3]{10,000}} \approx 1.11$, donc $k = \frac{12}{1.11} \approx 11$ bins.

La hauteur (**densité**) d'un bin est calculée comme suit :

$$\text{Densité} = \frac{\text{Nombre de points dans le bin}}{n \times w}, \quad (26)$$

où w est la largeur du bin, n est le nombre total d'échantillons, et le numérateur correspond au nombre d'observations tombant dans l'intervalle du bin.

Interprétation des Résultats

- **L'espérance** $\mathbb{E}[X] \approx 3.00$ est proche de la moyenne théorique, confirmant que les valeurs sont centrées autour de $\mu = 3$.
- **La variance** $\text{Var}(X) \approx 2.01$ est également proche de la valeur théorique, ce qui indique une dispersion des observations cohérente avec $\sigma^2 = 2$.
- **L'écart-type** $\sigma(X) \approx 1.42$ signifie que la majorité des observations se situent dans l'intervalle $[1.58, 4.42]$, conformément à la règle empirique.

Résumé: Mesures de la Loi Normale $\mathcal{N}(3, 2)$

- **Espérance** $\mathbb{E}[X] = 3.00$: La moyenne des observations.
- **Variance** $\text{Var}(X) = 2.00$: La dispersion autour de la moyenne.
- **Écart-type** $\sigma(X) = 1.41$: La mesure de dispersion ramenée à l'unité des observations.

La règle empirique pour la loi normale Pour une loi normale $\mathcal{N}(\mu, \sigma^2)$, la règle empirique s'applique comme suit:

- 68% des valeurs se situent dans l'intervalle $[\mu - \sigma, \mu + \sigma]$.
- 95% des valeurs se situent dans l'intervalle $[\mu - 2\sigma, \mu + 2\sigma]$.
- 99.7% des valeurs se situent dans l'intervalle $[\mu - 3\sigma, \mu + 3\sigma]$.

Conclusion La loi normale $\mathcal{N}(3, 2)$ illustre comment les données sont centrées autour de $\mu = 3$ avec une dispersion standard de $\sigma = 1.41$. L'histogramme montre une correspondance entre la densité empirique et la densité théorique, renforçant ainsi l'intuition sur les propriétés de la loi normale.

Exemple : Si un bin couvre l'intervalle $[2, 2.5]$ et contient 450 observations pour $n = 10,000$, alors :

$$\text{Densité} = \frac{450}{10,000 \times 0.5} = 0.09. \quad (27)$$

Cette densité approximative reflète à la fois la fréquence relative des observations dans ce bin et leur normalisation pour approcher la densité théorique de la loi normale.

2.1.6 Exemple 4 : Série temporelle avec tendance linéaire et bruit

Considérons une série temporelle modélisée par :

$$y_t = \alpha + \beta t + \varepsilon_t,$$

où :

- $\alpha = 5$: l'intercepte, représentant la valeur initiale,
- $\beta = 0.2$: le coefficient de pente, représentant la tendance linéaire,
- $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$: le bruit gaussien avec $\sigma^2 = 1$.

Simulation et Visualisation Nous générons une série temporelle de $n = 100$ observations. La tendance linéaire est donnée par $\alpha + \beta t$, et un bruit gaussien est ajouté à chaque point.




Figure 5: Série temporelle simulée avec tendance linéaire ($\alpha = 5$, $\beta = 0.2$) et bruit gaussien.

Calculs Statistiques : Valeurs Empiriques et Théoriques Les mesures suivantes ont été calculées à partir des données simulées et comparées à leurs valeurs théoriques basées sur le modèle :

- **Espérance empirique :**

$$\mathbb{E}[y_t] = \frac{1}{n} \sum_{t=1}^n y_t \approx 15.00.$$

Théoriquement, l'espérance est donnée par :

$$\mathbb{E}[y_t] = \alpha + \beta \cdot \mathbb{E}[t] = 5 + 0.2 \cdot \frac{n+1}{2} = 15.$$

- **Variance empirique :**

$$\text{Var}(y_t) = \frac{1}{n} \sum_{t=1}^n (y_t - \mathbb{E}[y_t])^2 \approx 34.61.$$

Théoriquement, la variance est donnée par :

$$\text{Var}(y_t) = \text{Var}(\varepsilon_t) = \sigma^2 = 1.$$

Toutefois, à cause de la contribution de la tendance linéaire, la dispersion globale des y_t est amplifiée.

- **Écart-type empirique :**

$$\sigma(y_t) = \sqrt{\text{Var}(y_t)} \approx 5.88.$$

Interprétation des Résultats

- **Tendance linéaire :** La ligne rouge en pointillés représente la composante déterministe $\alpha + \beta t$.
- **Bruit gaussien :** Les oscillations autour de la tendance sont dues au bruit ajouté, ici modélisé par une loi normale.
- **Zone de dispersion :** La zone jaune ($\pm\sigma$) montre l'étendue moyenne des fluctuations autour de la tendance.
- **Comparaison des valeurs :**
 - L'espérance empirique est cohérente avec la valeur théorique ($\mathbb{E}[y_t] = 15$).
 - La variance empirique est significativement plus grande que σ^2 , car elle inclut les contributions de la tendance.

Hypothèse implicite d'Équiprobabilité En calculant l'espérance empirique, nous faisons l'hypothèse implicite que chaque observation a la même importance statistique. Cette hypothèse revient à supposer que les données sont indépendantes et identiquement distribuées (*i.i.d.*). Cependant :

- **Cas favorable :** Cette hypothèse est raisonnable lorsqu'il n'existe pas de corrélation forte entre les observations.
- **Limites :** Si les observations y_t proviennent d'une distribution non uniforme ou sont corrélées (comme ici, en raison de la tendance linéaire), cela peut limiter l'interprétation de l'espérance et de la variance.

Conclusion Cet exemple illustre comment une série temporelle peut être décomposée en une tendance (composante déterministe) et un bruit (composante aléatoire). Les concepts d'espérance, de variance et d'écart-type permettent de quantifier les caractéristiques de ces séries. En comparant les mesures empiriques et théoriques, nous confirmons la validité du modèle utilisé et identifions l'impact de la tendance linéaire sur la variance globale.

Interprétation des calculs empiriques sans connaissance du modèle théorique
Si nous supposons que nous ne connaissons pas la structure théorique de notre série temporelle ($y_t = \alpha + \beta t + \varepsilon_t$), les calculs empiriques effectués sur la série nous permettraient d'obtenir certaines informations descriptives, tout en étant limités par l'absence d'un modèle explicatif. Voici une interprétation basée sur les résultats empiriques :

1. Analyse basée sur les calculs empiriques

- **Espérance empirique** ($\mathbb{E}[y_t] \approx 15.00$) : Cela nous informe que, sur l'ensemble des observations, la série a une moyenne proche de 15. Si la série représente une mesure comme des ventes, des températures, ou des performances, cela peut être interprété comme le "niveau moyen" attendu dans cette période donnée.
- **Variance empirique** ($\text{Var}(y_t) \approx 34.61$) : La variance nous indique que les valeurs observées montrent une dispersion modérée autour de leur moyenne. Une variance plus élevée pourrait suggérer une variabilité importante dans les données.
- **Écart-type empirique** ($\sigma(y_t) \approx 5.88$) : L'écart-type suggère que la plupart des valeurs (68%) se situent dans l'intervalle $[15 - 5.88, 15 + 5.88] = [9.12, 20.88]$, selon la règle empirique pour les données normalement distribuées.

2. Informations que nous pouvons extraire sans modèle théorique

- **Description générale de la série** : La série montre une dispersion modérée autour d'une moyenne de 15. Cela peut être interprété comme une variabilité attendue autour d'un certain niveau central.
- **Détection d'anomalies potentielles** : Si des observations dépassent largement $\mathbb{E}[y_t] \pm 2\sigma(y_t)$ (environ $[3.24, 26.76]$), elles pourraient être considérées comme des valeurs aberrantes ou des comportements atypiques.
- **Hypothèses initiales possibles** :
 - La valeur moyenne ($\mathbb{E}[y_t]$) suggère une tendance générale autour de 15.
 - La dispersion ($\sigma(y_t)$) peut suggérer une composante aléatoire dans les données.

Ces informations pourraient motiver une exploration supplémentaire pour détecter une tendance linéaire ou une saisonnalité.

3. Ce que nous ne savons pas sans connaître le modèle théorique

- **Composante déterministe** : En l'absence de modèle explicite, nous ne savons pas si la moyenne observée ($\mathbb{E}[y_t]$) est due à une composante déterministe (par exemple, une tendance linéaire) ou si elle est simplement issue des fluctuations aléatoires.
- **Structure sous-jacente des fluctuations** : La variance capture la dispersion totale, mais nous ne savons pas si cette dispersion est due à un bruit purement aléatoire ($\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$) ou si elle inclut également une variabilité liée à une tendance non détectée.

4. Interprétation pratique dans notre cas Si nous ignorons la structure théorique ($y_t = 5 + 0.2t + \varepsilon_t$), les calculs empiriques nous donneraient une description utile mais incomplète :

- **L'espérance empirique** ($\mathbb{E}[y_t] \approx 15.00$) peut être interprétée comme un "niveau central" des données, mais elle masque la présence d'une tendance linéaire (βt).
- **La variance empirique** ($\text{Var}(y_t) \approx 34.61$) est une mesure globale de la dispersion, mais elle mélange l'effet de la tendance et du bruit gaussien.
- **Sans connaissance du modèle théorique :**
 - **Hypothèses :** Nous pourrions suspecter une tendance linéaire à cause de la distribution non uniforme des valeurs autour de la moyenne.
 - **Limites :** Nous ne pouvons pas décomposer cette dispersion entre la part due à la tendance (βt) et celle due au bruit (ε_t).

5. Conclusion Sans connaître la structure théorique :

- Les calculs empiriques permettent une première description statistique de la série.
- Ils peuvent guider des hypothèses sur une potentielle tendance ou structure.
- Toutefois, ils restent limités pour identifier la nature exacte de la série (tendance, saisonnalité, bruit), car ils ne distinguent pas les composantes déterministes et aléatoires.

Pour une analyse plus approfondie et utile en pratique, une modélisation supplémentaire serait nécessaire, par exemple, via une régression linéaire pour détecter la tendance et estimer le bruit séparément.

Solution proposée : Formulation de l'hypothèse Nous proposons que la série temporelle puisse être représentée par une tendance linéaire approchée :

$$\hat{y}_t = \hat{\alpha} + \hat{\beta}t,$$

à laquelle s'ajoute un bruit. Cette hypothèse repose sur plusieurs éléments empiriques et méthodologiques issus de l'analyse des données. Voici les principales raisons et observations qui nous ont conduits à cette hypothèse :

1. Observation visuelle de la série temporelle

En examinant la série temporelle (graphiquement), nous avons remarqué une structure globale qui semble suivre une tendance linéaire. Cette tendance est visible dans l'évolution croissante des valeurs y_t avec le temps t . La présence de fluctuations autour de cette tendance suggère l'existence d'une composante aléatoire (ou bruit).

2. Calculs empiriques

- *Espérance empirique* ($\mathbb{E}[y_t]$) : Une moyenne globale de la série temporelle nous a donné un point de départ pour comprendre la "valeur centrale" des données.
- *Variance empirique* ($\text{Var}(y_t)$) : La dispersion autour de cette moyenne a confirmé que les données fluctuent de manière significative, ce qui justifie l'ajout d'un terme de bruit.

3. Régression linéaire comme modèle candidat

Nous avons utilisé la régression linéaire pour détecter et quantifier la relation linéaire entre y_t et t . Les résultats de cette régression nous ont donné :

- Un *intercepte estimé* ($\hat{\alpha}$) de la tendance,
- Une *pente estimée* ($\hat{\beta}$) représentant la croissance moyenne par unité de temps.

Ces estimations confirment qu'un modèle linéaire est adapté pour capturer la structure déterministe de la série.

4. Hypothèse implicite d'une composante aléatoire (bruit)

Les résidus ($\varepsilon_t = y_t - \hat{y}_t$) calculés après avoir ajusté la tendance linéaire sont supposés être :

- Moyennés autour de zéro ($\mathbb{E}[\varepsilon_t] = 0$),
- Non corrélés avec t (pas de structure linéaire résiduelle),
- Avec une variance faible ($\text{Var}(\varepsilon_t)$).

La distribution de ces résidus est supposée normale, conformément à l'hypothèse de bruit gaussien.

5. Pertinence statistique et simplicité

Le modèle linéaire est un modèle simple et parsimonieux, souvent utilisé comme premier modèle d'analyse lorsque des données montrent une tendance générale. Bien qu'il puisse exister des modèles plus complexes (non linéaires, saisonniers, etc.), une première approximation par un modèle linéaire est souvent suffisante pour décrire les données à un niveau global.

Conclusion Nous avons formulé l'hypothèse suivante pour représenter notre série temporelle :

$$y_t = \hat{\alpha} + \hat{\beta}t + \varepsilon_t.$$

Cette hypothèse repose sur :

- L'observation visuelle de la tendance,
- Les calculs empiriques de dispersion et de moyenne,
- L'ajustement par régression linéaire, qui a validé cette relation linéaire,
- L'hypothèse de bruit aléatoire gaussien, qui explique les fluctuations résiduelles.

Cette hypothèse permet de décomposer la série en deux parties : une **composante déterministe** (la tendance linéaire) et une **composante aléatoire** (le bruit).




Figure 6: Série temporelle simulée avec tendance linéaire ($\hat{y}_t = 5.0 + 0.2t$) et bruit gaussien. L'analyse montre les intervalles $\pm\sigma$ et $\pm 2\sigma$, ainsi que l'ajustement de la tendance linéaire.

2.1.7 Exemple 5 : Série temporelle stationnaire (Bruit blanc gaussien)

Considérons une série temporelle stationnaire modélisée comme un **bruit blanc gaussien** y_t , défini par :

$$y_t \sim \mathcal{N}(0, 1),$$

où :

- $E[y_t] = 0$ est l'espérance théorique,
- $Var(y_t) = 1$ est la variance théorique,
- $\sigma(y_t) = 1$ est l'écart-type théorique.

Simulation et Visualisation Nous avons généré une série temporelle de $n = 100$ observations correspondant à un bruit blanc gaussien. Les calculs statistiques théoriques et empiriques sont comparés dans la figure 7.

Calculs Statistiques Les résultats des calculs statistiques sont présentés ci-dessous :

- **Espérance empirique :**

$$E[y_t] = \frac{1}{n} \sum_{t=1}^n y_t \approx -0.10,$$

contre une espérance théorique $E[y_t] = 0$. La petite déviation observée est due à la taille finie de l'échantillon.




Figure 7: Série temporelle simulée : Bruit blanc gaussien avec comparaison des statistiques empiriques et théoriques.

- **Variance empirique :**

$$\text{Var}(y_t) = \frac{1}{n} \sum_{t=1}^n (y_t - \mathbb{E}[y_t])^2 \approx 0.82,$$

par rapport à une variance théorique $\text{Var}(y_t) = 1$. Cette valeur empirique est légèrement inférieure, mais reste cohérente avec le modèle théorique.

- **Écart-type empirique :**

$$\sigma(y_t) = \sqrt{\text{Var}(y_t)} \approx 0.90,$$

comparé à un écart-type théorique $\sigma(y_t) = 1$. Cela confirme une variabilité conforme aux attentes pour un bruit blanc gaussien.

Interprétation des Résultats

- La série temporelle est stationnaire, car les statistiques calculées (espérance et variance) restent constantes et proches de leurs valeurs théoriques au cours du temps.
- La dispersion autour de la moyenne est capturée par $\pm\sigma$, comme représenté dans la zone jaune sur la figure 7.
- La différence entre les statistiques empiriques et théoriques est attribuable à l'échantillon fini, et cette différence diminue lorsque la taille de l'échantillon augmente.

Conclusion Cet exemple illustre un cas classique de série temporelle stationnaire, où les valeurs fluctuent aléatoirement autour d'une moyenne fixe avec une variance constante. Ce type de série est une base importante pour de nombreuses analyses en statistique et en traitement de signaux.

Hypothèses basées sur les calculs empiriques Si nous supposons que la forme théorique de la série temporelle est inconnue, les calculs empiriques permettent de formuler une hypothèse simplifiée pour modéliser la série.

- **Observation visuelle** : La série montre des fluctuations aléatoires autour d'une moyenne apparente proche de 0. Aucune tendance linéaire ni saisonnalité n'est détectée.
- **Espérance empirique** ($\mathbb{E}[y_t] \approx -0.10$) : Cela suggère que la série est centrée autour de 0, sans biais significatif.
- **Variance empirique** ($\text{Var}(y_t) \approx 0.82$) : La dispersion des valeurs est modérée et semble constante dans le temps, ce qui est caractéristique d'un processus stationnaire.
- **Écart-type empirique** ($\sigma(y_t) \approx 0.90$) : Cela indique que la majorité des valeurs (68%) se situent dans l'intervalle $[-0.90, 0.90]$.

Hypothèse proposée En se basant sur ces observations, nous formulons l'hypothèse que la série temporelle peut être représentée par :

$$y_t = \varepsilon_t,$$

où ε_t est une composante aléatoire suivant une loi normale $\mathcal{N}(\mu, \sigma^2)$, avec :

- $\mu \approx 0$ (moyenne empirique),
- $\sigma \approx 0.90$ (écart-type empirique).

Hypothèses implicites

- La série est **stationnaire**, car ses statistiques (espérance et variance) ne varient pas dans le temps.
- Les valeurs successives y_t sont supposées **indépendantes**, comme attendu dans un bruit blanc.
- La distribution des valeurs est **symétrique** autour de la moyenne, ce qui est cohérent avec une loi normale.

Limites et Interprétation

- Si la structure théorique de la série est inconnue, cette hypothèse fournit une approximation utile mais simplifiée.
- Elle ne permet pas de détecter de potentielles dépendances temporelles ou de structures sous-jacentes plus complexes.
- Une analyse plus approfondie, comme un test d'indépendance ou l'exploration des autocorrélations, pourrait être nécessaire pour confirmer ces hypothèses.

2.1.8 Hypothèse d'Approximation : Bruit Blanc Gaussien

À partir de l'analyse empirique, nous formulons l'hypothèse que la série temporelle étudiée peut être approximée par un **bruit blanc gaussien** :

$$y_t \sim \mathcal{N}(\mu, \sigma^2),$$

où μ représente la moyenne et σ^2 la variance de la distribution. Cette hypothèse repose sur les éléments suivants :

Justifications de l'Hypothèse

- **Calculs statistiques** : Les valeurs empiriques calculées ($\mathbb{E}[y_t] \approx -0.10$, $\text{Var}(y_t) \approx 0.82$) sont proches des valeurs théoriques ($\mu = 0$, $\sigma^2 = 1$) attendues pour un bruit blanc gaussien.
- **Visualisation temporelle** : La série temporelle ne montre aucune tendance ni saisonnalité (figure 8), ce qui est cohérent avec un processus stationnaire.
- **Distribution des valeurs** : L'histogramme des données (figure 9) est bien ajusté par une densité normale, confirmant l'hypothèse de normalité.

Démarche pour Valider l'Hypothèse

1. **Analyse visuelle** : Observer l'absence de tendance ou de structure apparente dans la série temporelle.
2. **Calculs empiriques** : Estimer la moyenne ($\mathbb{E}[y_t]$) et la variance ($\text{Var}(y_t)$) de la série, puis les comparer aux valeurs théoriques.
3. **Analyse de la distribution** : Comparer l'histogramme des données à une densité normale ajustée ($\mathcal{N}(\mu, \sigma^2)$).

Espérance empirique $E[y_t] = -0.1038$
 Variance empirique $\text{Var}(y_t) = 0.8165$
 Écart-type empirique $\sigma(y_t) = 0.9036$




Figure 8: Série temporelle : bruit blanc gaussien et zone de dispersion ($\pm\sigma$).




Figure 9: Histogramme des valeurs et approximation par une densité normale.

Conclusion L'hypothèse que la série temporelle suit un bruit blanc gaussien repose sur des analyses empiriques cohérentes avec la théorie. Elle est validée par :

- La proximité des calculs empiriques et théoriques pour μ et σ^2 ,
- L'absence de structure temporelle discernable,
- La forme de la distribution des valeurs, proche de la normalité.

Cette hypothèse fournit une description utile pour la série étudiée et constitue une base solide pour d'éventuelles analyses ou modélisations supplémentaires.




Figure 10: Comparaison de la série temporelle et son approximation

3 Stationnarité et Mesures de Dépendance Temporelle

L'analyse des séries temporelles repose souvent sur l'hypothèse de stationnarité et sur l'étude des dépendances temporelles à l'aide de mesures telles que l'autocovariance et l'autocorrélation. Cette section présente successivement ces concepts essentiels.

3.1 Stationnarité des Séries Temporelles: Définitions

Soit $\{y_t\}_{t \in T}$ une série temporelle définie sur un ensemble d'indices $T \subset \mathbb{Z}$ (ou $T \subset \mathbb{R}$).

1. Stationnarité stricte (forte) La série $\{y_t\}$ est dite *strictement stationnaire* si, pour tout entier $n \geq 1$, pour tout ensemble d'indices $t_1, t_2, \dots, t_n \in T$ et pour tout décalage temporel h tel que $t_i + h \in T$ pour $i = 1, \dots, n$, la distribution conjointe des vecteurs

$$(y_{t_1}, y_{t_2}, \dots, y_{t_n})$$

et

$$(y_{t_1+h}, y_{t_2+h}, \dots, y_{t_n+h})$$

est identique.

En d'autres termes,

$$(y_{t_1}, y_{t_2}, \dots, y_{t_n}) \stackrel{d}{=} (y_{t_1+h}, y_{t_2+h}, \dots, y_{t_n+h}), \quad \forall n \geq 1, \forall t_1, \dots, t_n \in T, \forall h \text{ tel que } t_i + h \in T.$$

3

³Cette égalité se lit de la manière suivante : Pour tout entier $n \geq 1$, pour tout ensemble d'indices $t_1, t_2, \dots, t_n \in T$ et pour tout décalage h tel que $t_i + h \in T$ pour chaque i , la loi conjointe du vecteur $(y_{t_1}, y_{t_2}, \dots, y_{t_n})$ est identique à celle du vecteur $(y_{t_1+h}, y_{t_2+h}, \dots, y_{t_n+h})$. Autrement dit, si l'on décale simultanément l'ensemble des observations de h , leur distribution conjointe reste inchangée. Lorsqu'on exprime cette égalité en termes de densité (lorsque les densités jointes existent), on a :

$$f_{t_1, \dots, t_n}(x_1, \dots, x_n) = f_{t_1+h, \dots, t_n+h}(x_1, \dots, x_n),$$

pour tout $n \geq 1$, pour tous $t_1, \dots, t_n \in T$ et pour tout h tel que $t_i + h \in T$.

Cette propriété implique que toutes les caractéristiques probabilistes de la série (tous ses moments, fonctions génératrices, etc.) sont invariables par translation dans le temps⁴.

2. Stationnarité au second ordre (faible stationnarité) La série $\{y_t\}$ est dite *faiblement stationnaire* (ou stationnaire au second ordre) si seules les deux premières statistiques (les moments d'ordre 1 et 2) sont invariantes dans le temps. Plus précisément, il faut que :

1. **Constante de l'espérance** : Il existe une constante $\mu \in \mathbb{R}$ telle que

$$\mathbb{E}[y_t] = \mu, \quad \forall t \in T.$$

2. **Constante de la variance** : Il existe une constante $\sigma^2 < \infty$ telle que

$$\text{Var}(y_t) = \mathbb{E}[(y_t - \mu)^2] = \sigma^2, \quad \forall t \in T.$$

3. **Invariance de la covariance** : Pour tous $t, s \in T$, la covariance entre y_t et y_s dépend uniquement de la différence $t - s$. Autrement dit, il existe une fonction $\gamma : T \rightarrow \mathbb{R}$ telle que

$$\text{Cov}(y_t, y_s) = \gamma(t - s), \quad \forall t, s \in T.$$

Il est important de noter que la stationnarité au second ordre n'implique pas que l'intégralité de la distribution de la série soit invariante par translation dans le temps, mais seulement que les deux premiers moments le soient. Cette notion est souvent suffisante pour de nombreuses applications en modélisation des séries temporelles.

3.2 Mesures de Dépendance Temporelle

Pour comprendre comment les observations à différents instants sont reliées, on utilise principalement deux outils : l'autocovariance et l'autocorrélation.

⁴La loi conjointe (ou distribution conjointe) du vecteur $(y_{t_1}, y_{t_2}, \dots, y_{t_n})$ décrit la manière dont les variables aléatoires $y_{t_1}, y_{t_2}, \dots, y_{t_n}$ se comportent ensemble. Elle se définit par la fonction de répartition conjointe

$$F_{t_1, \dots, t_n}(x_1, \dots, x_n) = \mathbb{P}(y_{t_1} \leq x_1, y_{t_2} \leq x_2, \dots, y_{t_n} \leq x_n),$$

ou, dans le cas continu, par la densité jointe

$$f_{t_1, \dots, t_n}(x_1, \dots, x_n) = \frac{\partial^n}{\partial x_1 \partial x_2 \dots \partial x_n} F_{t_1, \dots, t_n}(x_1, \dots, x_n).$$

La stationnarité stricte impose que ces fonctions soient invariantes par translation temporelle, c'est-à-dire que

$$F_{t_1, \dots, t_n}(x_1, \dots, x_n) = F_{t_1+h, \dots, t_n+h}(x_1, \dots, x_n)$$

et, lorsque la densité existe,

$$f_{t_1, \dots, t_n}(x_1, \dots, x_n) = f_{t_1+h, \dots, t_n+h}(x_1, \dots, x_n),$$

pour tout décalage h tel que $t_i + h \in T$.

3.2.1 Autocovariance

L'**autocovariance** quantifie la dépendance linéaire entre deux valeurs d'une série temporelle séparées par un décalage (*lag*) k . Sa définition générale est :

$$\gamma(k) = \text{Cov}(y_t, y_{t-k}) = \mathbb{E}\left[(y_t - \mathbb{E}[y_t])(y_{t-k} - \mathbb{E}[y_{t-k}])\right].$$

Pour une série **stationnaire au second ordre** (où $\mathbb{E}[y_t] = \mu$ pour tout t), cette expression se simplifie en :

$$\gamma(k) = \mathbb{E}\left[(y_t - \mu)(y_{t-k} - \mu)\right].$$

Propriétés

- **Symétrie** : $\gamma(k) = \gamma(-k)$.
- **Maximum à $k = 0$** : $\gamma(0) = \text{Var}(y_t) = \sigma^2$.
- **Décroissance avec k** : Pour de nombreuses séries, $|\gamma(k)|$ décroît lorsque $|k|$ augmente, indiquant que l'influence des valeurs passées s'estompe avec le temps.

Estimation empirique Pour une série observée $\{y_t\}_{t=1}^n$, l'estimateur de l'autocovariance pour un lag k est :

$$\hat{\gamma}(k) = \frac{1}{n} \sum_{t=k+1}^n (y_t - \bar{y})(y_{t-k} - \bar{y}),$$

où $\bar{y} = \frac{1}{n} \sum_{t=1}^n y_t$ est la moyenne empirique.

Interprétation

- Si $\gamma(k) > 0$, les valeurs y_t et y_{t-k} sont **positivement corrélées** (si l'une dépasse la moyenne, l'autre tend également à être élevée).
- Si $\gamma(k) < 0$, elles sont **négativement corrélées** (une valeur élevée tend à être suivie d'une valeur basse, et vice-versa).
- Si $\gamma(k) = 0$, il n'existe pas de relation linéaire discernable pour ce décalage.

3.2.2 Autocorrélation

L'**autocorrélation** est la version normalisée de l'autocovariance, ce qui permet d'évaluer la force et la direction de la dépendance sans tenir compte de l'échelle des données. Elle est définie par :

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)} = \frac{\text{Cov}(y_t, y_{t-k})}{\text{Var}(y_t)}.$$

Caractéristiques et Interprétation

- $\rho(k)$ est un coefficient adimensionnel prenant des valeurs dans $[-1, +1]$.
- $\rho(k) = +1$ signifie une corrélation **parfaite et positive**.
- $\rho(k) = -1$ indique une corrélation **parfaite et négative**.
- $\rho(k) = 0$ signifie l'absence de corrélation linéaire.

Dans une série stationnaire, $\rho(k)$ ne dépend que du décalage k , ce qui est exploité notamment dans l'analyse via la fonction d'autocorrélation (ACF).

Applications L'autocorrélation est largement utilisée pour :

- Déterminer la structure de dépendance temporelle.
- Identifier l'ordre des modèles AR, MA et ARMA.
- Détecter la présence de saisonnalité (par exemple, par des pics à des lags spécifiques).
- Vérifier l'absence d'autocorrélation dans les résidus d'un modèle.

3.3 Exemple et Application : Vers une Modélisation Approximative

L'étude conjointe de l'autocovariance et de l'autocorrélation aide à mieux comprendre la structure temporelle d'une série et à valider des hypothèses de modélisation. Considérons l'exemple d'une série présentant une tendance linéaire perturbée par un bruit aléatoire.

Modèle Approximatif Un modèle linéaire simple peut être proposé :

$$\hat{y}_t = \hat{\alpha} + \hat{\beta}t + \varepsilon_t,$$

où :

- $\hat{\alpha}$ est l'estimation de l'intercepte (proche de $\mathbb{E}[y_t]$).
- $\hat{\beta}$ est la pente représentant la tendance linéaire.
- t représente le temps.
- ε_t est le terme d'erreur (les résidus).

Apport des Mesures d'Autocovariance et d'Autocorrélation

- La décroissance de $\gamma(k)$ et de $\rho(k)$ avec l'augmentation du lag k indique que l'influence des valeurs passées s'atténue avec le temps.
- Des valeurs significatives de $\rho(k)$ pour de petits lags confirment une dépendance à court terme, typique des séries avec tendance linéaire perturbée par du bruit.

Illustrations Graphiques Les figures ci-dessous illustrent les concepts présentés :




Figure 11: Exemple d'autocovariance et d'autocorrélation pour une série temporelle linéaire avec bruit.

$y_{10} = 6.74$, $y_5 = 5.97$
Moyenne empirique = 15.00
Contribution au calcul de l'autocovariance ($k=5$) = 74.59




Figure 12: Illustration des lags.




Figure 13: Approximation de la série temporelle en utilisant l'espérance, la variance, l'autocovariance et l'autocorrélation.

Interprétations Graphiques

- La valeur $\gamma(0)$ correspond à la variance empirique et $\rho(0) = 1$ par définition.
- La décroissance régulière de $\gamma(k)$ et de $\rho(k)$ avec l'augmentation du lag k confirme que l'influence des observations passées diminue avec le temps.

Conclusion Les mesures d'autocovariance et d'autocorrélation sont des outils essentiels pour décrypter la structure temporelle d'une série. Elles permettent notamment de :

- Détecter des motifs ou cycles récurrents.
- Choisir le modèle le plus approprié (par exemple, déterminer l'ordre d'un modèle ARMA).
- Valider l'adéquation d'une modélisation, comme l'approximation par une tendance linéaire perturbée par du bruit.

3.4 Tests de Stationnarité

Pour déterminer si une série temporelle est stationnaire, plusieurs tests statistiques sont disponibles. Ces tests évaluent les propriétés de la série afin de guider les éventuelles transformations nécessaires avant de passer à une modélisation prédictive.

Principaux tests de stationnarité:

- **Test Augmented Dickey-Fuller (ADF)**
- **Test KPSS (Kwiatkowski-Phillips-Schmidt-Shin)**
- **Test de Phillips-Perron (PP)**

3.4.1 Test Augmented Dickey-Fuller (ADF)

Le test ADF est un test statistique utilisé pour déterminer si une série temporelle est stationnaire ou non, en testant la présence d'une **racine unitaire** dans le processus générateur de données.

Formulation mathématique Le test ADF repose sur l'estimation de la régression suivante :

$$\Delta y_t = \alpha + \beta t + \phi y_{t-1} + \sum_{i=1}^p \theta_i \Delta y_{t-i} + \varepsilon_t$$

où :

- $\Delta y_t = y_t - y_{t-1}$ est la première différence de la série temporelle.
- α est une constante (ou terme d'interception).
- βt est un terme de tendance linéaire (optionnel).
- y_{t-1} est la valeur retardée de la série temporelle.
- ϕ est le paramètre clé testé pour la racine unitaire.
- θ_i sont les coefficients associés aux termes différenciés retardés.
- p est le nombre de retards inclus (choisi pour capturer la corrélation résiduelle).
- ε_t est un terme d'erreur blanche.

Hypothèses du test

- **Hypothèse nulle (H_0)** : La série possède une racine unitaire, donc elle est **non stationnaire**.

$$H_0 : \phi = 0$$

- **Hypothèse alternative (H_1)** : La série est **stationnaire**.

$$H_1 : \phi < 0$$

Étapes du test

1. **Différenciation de la série** : On calcule Δy_t pour analyser les changements au lieu des niveaux de la série.
2. **Régression sur les termes retardés** : On ajuste un modèle de régression incluant y_{t-1} , les termes différenciés retardés Δy_{t-i} , et éventuellement une constante α et une tendance βt .
3. **Test du paramètre ϕ** :
 - Si $\phi = 0$, la série possède une racine unitaire, et donc elle est non stationnaire.
 - Si $\phi < 0$, la série est stationnaire.

Statistique de test La statistique utilisée pour le test est donnée par :

$$ADF = \frac{\hat{\phi}}{SE(\hat{\phi})}$$

où :

- $\hat{\phi}$ est l'estimation du paramètre ϕ .
- $SE(\hat{\phi})$ est l'erreur standard de $\hat{\phi}$.

Cette statistique est comparée à des valeurs critiques provenant de la distribution Dickey-Fuller (non standard).

Interprétation des résultats

- Si $ADF < \text{valeur critique}$, on **rejette** H_0 et on conclut que la série est stationnaire.
- Si $ADF \geq \text{valeur critique}$, on **n'échoue pas à rejeter** H_0 et on conclut que la série est non stationnaire.

Types de modèles testés Le test ADF peut inclure différents modèles selon les propriétés de la série temporelle :

- **Sans constante ni tendance :**

$$\Delta y_t = \phi y_{t-1} + \sum_{i=1}^p \theta_i \Delta y_{t-i} + \varepsilon_t$$

Utilisé si la série oscille autour de zéro sans tendance ni moyenne.

- **Avec constante seulement :**

$$\Delta y_t = \alpha + \phi y_{t-1} + \sum_{i=1}^p \theta_i \Delta y_{t-i} + \varepsilon_t$$

Utilisé si la série oscille autour d'une moyenne constante.

- **Avec constante et tendance :**

$$\Delta y_t = \alpha + \beta t + \phi y_{t-1} + \sum_{i=1}^p \theta_i \Delta y_{t-i} + \varepsilon_t$$

Utilisé si la série montre une tendance linéaire.

Limites du test ADF

- **Sensibilité au nombre de retards (p) :** Une mauvaise sélection peut entraîner des conclusions erronées.
- **Faible puissance :** Le test peut manquer de puissance pour détecter la stationnarité dans des échantillons de petite taille.
- **Hypothèse forte :** Il suppose que l'erreur ε_t est un bruit blanc, ce qui peut ne pas être vrai dans certains cas.

Conclusion Le test ADF est un outil puissant pour détecter la non-stationnarité, mais il est souvent utilisé en complément d'autres tests (comme KPSS) et d'une analyse visuelle pour confirmer les propriétés de la série.

3.4.2 Test KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

Le test KPSS est un test statistique utilisé pour vérifier si une série temporelle est stationnaire autour d'une **moyenne constante** ou d'une **tendance déterministe**. Contrairement au test ADF, le test KPSS a une hypothèse nulle qui suppose la stationnarité.

Formulation mathématique Le modèle général pour le test KPSS est donné par :

$$y_t = \mu + \beta t + r_t + \varepsilon_t$$

où :

- μ est une constante.
- βt est une tendance déterministe (optionnelle).
- r_t est un processus de marche aléatoire (indiquant la non-stationnarité).
- ε_t est un bruit blanc.

Le test KPSS mesure la variance de r_t (appelée "variance de dérive"). Si cette variance est significative, la série est considérée comme non stationnaire.

Hypothèses du test

- **Hypothèse nulle (H_0)** : La série est **stationnaire** autour d'une moyenne constante ou d'une tendance déterministe.
- **Hypothèse alternative (H_1)** : La série est **non stationnaire** en raison de la présence d'une racine unitaire.

Étapes du test

1. **Décomposition de la série** : On sépare la tendance déterministe ($\mu + \beta t$) du reste de la série.
2. **Calcul des résidus** : On estime les résidus r_t en ajustant le modèle.
3. **Calcul de la statistique KPSS** :

$$KPSS = \frac{1}{T^2} \sum_{t=1}^T \left(\sum_{j=1}^t \hat{r}_j \right)^2 / \hat{\sigma}^2$$

où :

- $\hat{r}_j$ sont les résidus estimés.
- $\hat{\sigma}^2$ est une estimation de la variance des résidus ε_t .
- T est la longueur de la série.

Statistique de test La statistique KPSS suit une distribution critique dérivée empiriquement. Les valeurs critiques dépendent du niveau de signification ($\alpha = 0.1, 0.05, 0.01$).

Interprétation des résultats

- Si $KPSS >$ valeur critique, on **rejette** H_0 et on conclut que la série est non stationnaire.
- Si $KPSS \leq$ valeur critique, on **n'échoue pas à rejeter** H_0 et on conclut que la série est stationnaire.

Types de modèles testés Le test KPSS peut être utilisé dans deux contextes :

- **Stationnarité autour d'une moyenne constante** : On teste si la série oscille autour d'une moyenne constante ($\beta = 0$).
- **Stationnarité autour d'une tendance déterministe** : On teste si la série oscille autour d'une tendance ($\beta \neq 0$).

Limites du test KPSS

- **Complémentarité avec le test ADF** : Le test KPSS est souvent utilisé conjointement avec le test ADF, car leurs hypothèses nulles sont opposées.
- **Sensibilité aux valeurs extrêmes** : Les résultats du test peuvent être influencés par des anomalies dans les données.
- **Hypothèse forte** : Il suppose que le terme d'erreur ε_t est un bruit blanc, ce qui peut ne pas être vérifié.

Conclusion Le test KPSS est utile pour détecter la non-stationnarité sous forme de tendance ou de dérive stochastique. En combinaison avec le test ADF, il fournit une évaluation robuste de la stationnarité d'une série temporelle.

3.4.3 Test de Phillips-Perron (PP)

Le test de Phillips-Perron est une alternative au test Augmented Dickey-Fuller (ADF) pour tester la présence d'une **racine unitaire**, et donc la **non-stationnarité** d'une série temporelle. Ce test est particulièrement adapté lorsque les erreurs ne sont pas indépendantes et identiquement distribuées (*i.i.d.*) ou présentent de l'hétéroscédasticité.

Formulation mathématique Le test PP est basé sur une version simplifiée de la régression utilisée dans le test ADF :

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \varepsilon_t$$

où :

- $\Delta y_t = y_t - y_{t-1}$ représente la différence de la série à deux instants consécutifs.
- α est une constante.
- βt est une tendance temporelle optionnelle.
- γ est le coefficient lié à la présence d'une racine unitaire.
- ε_t est le terme d'erreur.

Hypothèses du test

- **Hypothèse nulle (H_0)** : La série possède une racine unitaire, donc elle est non stationnaire.
- **Hypothèse alternative (H_1)** : La série est stationnaire.

Différences avec le test ADF Contrairement au test ADF, le test PP :

- Ne nécessite pas d'ajouter explicitement des termes de retard (Δy_{t-k}) pour corriger l'autocorrélation dans les résidus.
- Ajuste la statistique de test pour prendre en compte une structure d'autocorrélation et d'hétéroscédasticité dans les résidus.
- Utilise une correction non paramétrique pour estimer la matrice de variance-covariance des résidus.

Statistique du test La statistique du test PP est donnée par :

$$Z_\tau = \frac{\hat{\gamma}}{SE(\hat{\gamma})}$$

où :

- $\hat{\gamma}$ est l'estimation du coefficient de y_{t-1} dans la régression.
- $SE(\hat{\gamma})$ est l'erreur standard corrigée de $\hat{\gamma}$.

Une correction est ensuite appliquée pour ajuster Z_τ en fonction de l'hétéroscédasticité et de l'autocorrélation des résidus.

Interprétation des résultats

- Si $Z_\tau >$ valeur critique, on **rejette** H_0 et on conclut que la série est stationnaire.
- Si $Z_\tau \leq$ valeur critique, on **n'échoue pas à rejeter** H_0 et on conclut que la série est non stationnaire.

Avantages du test PP

- **Robustesse à l'hétéroscédasticité** : Le test PP est mieux adapté aux séries présentant une hétéroscédasticité dans les résidus.
- **Simplicité** : Il évite d'avoir à choisir explicitement le nombre de lags, comme dans le test ADF.

Limites du test PP

- **Sensibilité à la taille de l'échantillon** : Comme le test ADF, le test PP peut manquer de puissance avec des échantillons de petite taille.
- **Hypothèses sur les résidus** : Bien qu'il corrige l'autocorrélation et l'hétéroscédasticité, les résultats dépendent de la qualité de cette correction.

Conclusion Le test de Phillips-Perron est une méthode efficace pour tester la stationnarité des séries temporelles, particulièrement en présence de résidus non i.i.d. ou hétéroscédastiques. Il est souvent utilisé conjointement avec d'autres tests, comme l'ADF et le KPSS, pour obtenir une évaluation robuste de la stationnarité.

Pourquoi tester la stationnarité?

- De nombreux modèles prédictifs, tels que les modèles **ARIMA** (Auto-Regressive Integrated Moving Average), supposent que la série d'entrée est stationnaire.
- Si la série est non stationnaire, des transformations comme la **différenciation** (soustraction de valeurs consécutives) ou le **détournement de tendance** sont nécessaires pour obtenir une série stationnaire.
- Les tests de stationnarité fournissent des informations précieuses pour choisir la meilleure méthode de transformation.

Applications pratiques: La stationnarité est essentielle pour interpréter correctement les résultats des modèles temporels. Une série non stationnaire peut conduire à des biais dans les prédictions et les diagnostics. Par exemple:

- Une série avec tendance peut donner des autocorrélations élevées même si elle est purement aléatoire.
- Une série stationnaire garantit que les dépendances temporelles mesurées, comme l'autocorrélation, sont fiables et interprétables.

Conclusion: Tester la stationnarité d'une série temporelle est une étape cruciale pour une analyse robuste. En appliquant des tests tels que l'ADF, le KPSS ou le PP, on peut déterminer si des transformations sont nécessaires avant d'utiliser des modèles prédictifs ou d'étudier des relations temporelles complexes.

4 Rôle de ces quantités

Les quantités statistiques précédemment définies jouent un rôle essentiel dans l'analyse des séries temporelles. Elles permettent de caractériser la structure des données et d'orienter le choix des modèles d'analyse et de prévision.

Espérance et Variance L'**espérance** $\mathbb{E}[y_t]$ et la **variance** $\text{Var}(y_t)$ fournissent des informations de base sur la structure globale de la série:

- L'espérance représente la **tendance centrale** de la série temporelle. Elle permet d'identifier si la série présente une moyenne constante ou si elle évolue dans le temps.
- La variance quantifie la **dispersion** des valeurs autour de leur moyenne, indiquant ainsi l'amplitude des fluctuations de la série.

Dans le cas d'une série **non stationnaire**, la moyenne et la variance peuvent varier avec le temps, ce qui complique l'analyse et nécessite des transformations (*par exemple, la différenciation*) avant d'appliquer certains modèles.

Autocovariance et Autocorrélation L'**autocovariance** et l'**autocorrélation** sont des outils essentiels pour analyser la **dépendance temporelle** dans les séries temporelles.

Définitions

- **Autocovariance** ($\gamma(k)$) : Elle mesure la relation linéaire entre deux valeurs d'une série temporelle séparées par un **décalage (lag)** k . Elle est définie comme :

$$\gamma(k) = \mathbb{E}[(y_t - \mu)(y_{t-k} - \mu)],$$

où μ est l'espérance de la série y_t .

- **Autocorrélation** ($\rho(k)$) : Il s'agit de la version normalisée de l'autocovariance. Elle exprime le degré de corrélation linéaire entre y_t et y_{t-k} , donné par :

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)},$$

où $\gamma(0)$ représente la variance de la série ($\gamma(0) = \text{Var}(y_t)$).

Décalages (lags) Un **décalage (lag)** k correspond à la différence en termes de temps entre deux points de la série temporelle :

- Pour $k = 1$, on mesure la relation entre y_t et y_{t-1} .
- Pour $k = 2$, on mesure la relation entre y_t et y_{t-2} , et ainsi de suite.

L'analyse pour plusieurs k permet d'explorer :

- Les **dépendances à court terme** (k faible).
- Les **dépendances à long terme** (k élevé).
- La présence éventuelle de motifs **cycliques ou saisonniers**.

Étapes du calcul

1. **Centrage des données** : Les données y_t sont centrées autour de leur moyenne empirique $\bar{y}$:

$$\hat{\gamma}(k) = \frac{1}{n} \sum_{t=k+1}^n (y_t - \bar{y})(y_{t-k} - \bar{y}),$$

où n est la taille de la série.

2. **Normalisation** : L'autocorrélation est obtenue en divisant l'autocovariance par la variance :

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}.$$

3. **Visualisation** : On représente graphiquement $\rho(k)$ en fonction de k pour étudier la structure temporelle.

Exemple pratique Prenons l'exemple d'un **bruit blanc gaussien**. En calculant $\rho(k)$ pour différents k , nous obtenons :

- Pour $k = 0$, $\rho(0) = 1$ (autocorrélation maximale).
- Pour $k > 0$, $\rho(k) \approx 0$, ce qui confirme l'absence de dépendance temporelle, caractéristique du bruit blanc.

Un graphique représentant $\rho(k)$ pour des k successifs aide à visualiser cette absence de corrélation.

Interprétation et Modélisation

- Si des $\rho(k)$ significatifs sont observés pour certains $k > 0$, cela indique une **dépendance temporelle**, nécessitant un modèle plus complexe, comme :
 - **AR (Auto-Regressive)** : Capture les relations entre y_t et ses valeurs passées ($y_{t-1}, y_{t-2}, \dots$).
 - **MA (Moving Average)** : Modélise les dépendances basées sur les résidus passés.
 - **ARIMA (Auto-Regressive Integrated Moving Average)** : Combine différenciation, autoregression et moyenne mobile pour gérer les séries non stationnaires.
- Dans le cas de notre exemple de bruit blanc, $\rho(k) \approx 0$ pour $k > 0$, confirmant l'absence de mémoire temporelle.

Stationnarité et Modélisation De nombreux modèles de séries temporelles, comme **ARIMA**, **SARIMA** (Seasonal ARIMA) ou **GARCH** (Generalized Autoregressive Conditional Heteroskedasticity), reposent sur l'hypothèse de **stationnarité**.

- Une série **stationnaire** a des propriétés statistiques invariantes dans le temps, ce qui facilite son analyse et sa modélisation.
- Si une série est **non stationnaire**, elle peut nécessiter des transformations comme :
 - **Le débiaisage**: Suppression d'une tendance à long terme.
 - **La différenciation**: Transformation $\Delta y_t = y_t - y_{t-1}$ pour rendre la moyenne constante.

Résumé et Importance

- **L'espérance et la variance** décrivent les **propriétés de base** d'une série et son niveau de fluctuations.
- **L'autocovariance et l'autocorrélation** permettent de comprendre la **structure temporelle** des données et d'identifier la présence de **dépendances**.
- **La stationnarité** est une hypothèse clé pour l'application de nombreux modèles prédictifs, et elle peut être obtenue via des transformations si nécessaire.

5 Opérations mathématiques courantes sur les séries temporelles

L'analyse des séries temporelles repose sur de nombreuses transformations et opérations destinées à stabiliser leurs propriétés statistiques, à améliorer leur interprétabilité et à préparer les données pour la modélisation. Parmi ces techniques, on retrouve notamment la différenciation, la transformation logarithmique, le lissage par moyenne mobile, ainsi que la modélisation à l'aide de processus stochastiques et de fonctions d'autocorrélation. Pour illustrer ces concepts, des exemples simples accompagnés de scripts Python sont présentés.

5.1 Transformations des séries temporelles

5.1.1 Différenciation

La **différenciation** permet d'éliminer les tendances à long terme et d'obtenir une série plus stationnaire. On commence par calculer la *première différence* de la série $\{y_t\}$:

$$\Delta y_t = y_t - y_{t-1}.$$

Cette transformation tend à supprimer une tendance linéaire.

Exemple de différenciation : Considérons une série simulée par

$$y_t = 2t + \epsilon_t,$$

où ϵ_t est un bruit blanc gaussien. La Figure 14 montre la série originale et sa première différence.




Figure 14: Série temporelle avec tendance linéaire et première différence.

5.1.2 Transformation logarithmique

La **transformation logarithmique** est utilisée pour stabiliser la variance, notamment lorsque l'amplitude des fluctuations augmente avec le niveau de la série. On définit :

$$z_t = \log(y_t).$$

Exemple de transformation logarithmique : Soit la série suivante avec une croissance exponentielle :

$$y_t = 5e^{0.1t}.$$

La transformation logarithmique permet d'obtenir :

$$\log(y_t) = \log(5) + 0.1t,$$

transformant ainsi une tendance exponentielle en tendance linéaire (voir Figure 15).




Figure 15: Transformation logarithmique d'une série temporelle.

5.1.3 Moyenne mobile

La **moyenne mobile** est une méthode de lissage qui permet de réduire les fluctuations à court terme pour mettre en évidence la tendance sous-jacente.

La moyenne mobile simple (SMA) sur une fenêtre de taille k est définie par :

$$SMA_t = \frac{1}{k} \sum_{i=0}^{k-1} y_{t-i}.$$

Exemple de moyenne mobile : Pour une série bruitée simulée avec tendance, lissage par une moyenne mobile de taille $k = 5$ permet de mieux visualiser la tendance générale (voir Figure 16).




Figure 16: Moving Average d'une série temporelle.

5.2 Processus stochastiques et modèles de séries temporelles

Un **processus stochastique** est une suite de variables aléatoires indexées dans le temps. Il permet de modéliser l'évolution aléatoire d'un phénomène.

5.2.1 Bruit blanc

Le **bruit blanc** est le processus de référence. Il est caractérisé par :

- $\mathbb{E}[\epsilon_t] = 0$,
- $\text{Var}(\epsilon_t) = \sigma^2$ constant,
- $\text{Cov}(\epsilon_t, \epsilon_{t-k}) = 0$ pour tout $k \neq 0$.

5.2.2 Modèles linéaires

Processus AR (AutoRegressif) Un modèle **AR(p)** s'exprime par :

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \epsilon_t.$$

La stationnarité est assurée si les racines du polynôme caractéristique

$$1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p = 0$$

sont en dehors du cercle unité.

Exemple de processus AR(1) : Considérons le modèle AR(1) suivant :

$$y_t = 0.7 y_{t-1} + \epsilon_t,$$

où ϵ_t est un bruit blanc. La Figure 17 illustre une série simulée à partir de ce modèle.




Figure 17: Processus AR.

Processus MA (Moving Average) Un modèle **MA(q)** se définit par :

$$y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}.$$

Ici, y_t est exprimé en fonction du bruit blanc présent et passé. Ce modèle est toujours stationnaire.

Exemple de processus MA(1) : Considérons un modèle MA(1) défini par :

$$y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1},$$

avec, par exemple, $\mu = 0$ et $\theta_1 = 0.5$. Dans ce modèle, chaque valeur y_t dépend du bruit blanc actuel ϵ_t et du bruit blanc précédent ϵ_{t-1} . La Figure 18 illustre une série simulée à partir de ce modèle.




Figure 18: Processus MA.

Processus ARMA (AutoRegressive Moving Average)

Processus ARMA (AutoRegressive Moving Average) Le modèle **ARMA(p, q)** combine les deux approches précédentes :

$$y_t = c + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}.$$

Il s'applique aux séries déjà stationnaires.

Exemple de processus ARMA(1,1): Considérons un modèle ARMA(1,1) défini par :

$$y_t = 0.6 y_{t-1} + \epsilon_t + 0.4 \epsilon_{t-1},$$

avec $c = 0$. La Figure 19 illustre une série simulée à partir de ce modèle.




Figure 19: Série temporelle simulée - Processus ARMA(1,1)

Processus ARIMA (AutoRegressive Integrated Moving Average) Pour traiter les séries non stationnaires, le modèle **ARIMA(p, d, q)** inclut une étape de différenciation d'ordre d :

$$\Delta^d y_t = (1 - B)^d y_t,$$

où B est l'opérateur de retard défini par $By_t = y_{t-1}$. Le paramètre d indique le nombre de différenciations nécessaires pour obtenir la stationnarité.

Exemple de processus ARIMA(1,1,1): Considérons un modèle ARIMA(1,1,1). Dans ce modèle, la série non stationnaire $\{y_t\}$ est différenciée une fois afin d'obtenir une série $\Delta y_t = y_t - y_{t-1}$ qui suit un processus ARMA(1,1) défini par :

$$\Delta y_t = 0.5 \Delta y_{t-1} + \epsilon_t - 0.3 \epsilon_{t-1}.$$

La Figure 20 illustre une série simulée à partir de ce modèle.




Figure 20: Série temporelle simulée - Processus ARIMA(1,1,1)

6 Fonctions et théorèmes clés en séries temporelles

6.0.1 Fonction d'autocorrélation (ACF)

L'ACF, comme on avait déjà dit, mesure la corrélation entre y_t et y_{t-k} :

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)},$$

avec $\gamma(k) = \mathbb{E}[(y_t - \mu)(y_{t-k} - \mu)]$. Une décroissance rapide de $\rho(k)$ indique une dépendance faible à long terme.

6.0.2 Fonction d'autocorrélation partielle (PACF)

La **fonction d'autocorrélation partielle** (PACF) mesure la corrélation directe entre y_t et y_{t-k} après avoir éliminé l'influence des observations intermédiaires $\{y_{t-1}, y_{t-2}, \dots, y_{t-k+1}\}$.

Définition formelle : Soit ϕ_{kk} le coefficient obtenu en ajustant un modèle autorégressif d'ordre k sur la série :

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_k y_{t-k} + \epsilon_t.$$

Le coefficient ϕ_{kk} est la **partial autocorrelation** à lag k et représente la corrélation entre y_t et y_{t-k} une fois que l'on a contrôlé pour les effets de $y_{t-1}, \dots, y_{t-k+1}$.

Une autre manière de voir la PACF est de considérer qu'elle fournit la contribution pure de y_{t-k} dans la prédiction de y_t après que l'on a pris en compte tous les lags intermédiaires.

Utilité et interprétation :

- **Détermination de l'ordre d'un modèle AR :** Dans un modèle $AR(p)$, la PACF montre généralement des valeurs significatives jusqu'au lag p puis chute brusquement à zéro. Cela aide à identifier l'ordre p approprié pour le modèle autorégressif.

- **Désambiguïsation des effets en cascade** : Contrairement à l'ACF, qui mesure à la fois les effets directs et indirects (via les corrélations entre les différents lags), la PACF permet d'isoler l'effet direct d'un lag donné.
- **Méthode de régression** : La PACF à lag k peut être obtenue en estimant par régression un modèle $AR(k)$ et en prenant le coefficient associé à y_{t-k} . On peut également la calculer en résolvant les équations de Yule-Walker pour un modèle $AR(k)$.

Exemple d'ACF et PACF : La Figure 21 affiche l'ACF et la PACF d'une série simulée, par exemple issue d'un modèle $AR(1)$. Cette illustration montre comment la PACF devient négligeable après le premier lag pour un processus $AR(1)$.




Figure 21: Fonction d'autocorrélation (ACF) et fonction d'autocorrélation partielle (PACF) d'une série $AR(1)$. La PACF chute brusquement après le premier lag, indiquant un modèle $AR(1)$.

6.0.3 Théorème de Wold

Le **théorème de Wold** stipule que tout processus stationnaire au second ordre peut être décomposé en deux composantes :

1. Une composante déterministe, qui correspond aux tendances ou cycles prévisibles (parfois nulle dans le cas de séries purement aléatoires).
2. Une composante stochastique, qui peut être représentée par un modèle $MA(\infty)$,

c'est-à-dire par une somme infinie de chocs passés pondérés :

$$y_t = \sum_{i=0}^{\infty} \theta_i \epsilon_{t-i}.$$

Cette décomposition permet de représenter la partie aléatoire d'une série par une suite d'effets découlant de chocs passés.

Exemple : Décomposition de Wold pour un processus AR(1) Considérons un processus AR(1) défini par :

$$y_t = \phi y_{t-1} + \epsilon_t,$$

avec $|\phi| < 1$. Il est bien connu que ce processus admet la représentation :

$$y_t = \epsilon_t + \phi \epsilon_{t-1} + \phi^2 \epsilon_{t-2} + \dots,$$

c'est-à-dire que les coefficients θ_i de la représentation MA(∞) sont $\theta_i = \phi^i$. La Figure 22 illustre la décroissance exponentielle des coefficients θ_i pour $\phi = 0.7$.




Figure 22: Coefficients $\theta_i = \phi^i$ pour un processus AR(1) avec $\phi = 0.7$, illustrant la décomposition de Wold.

6.0.4 Équations de Yule-Walker

Pour un processus AR(p) défini par :

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \epsilon_t,$$

les **équations de Yule-Walker** relient les coefficients ϕ_i aux autocovariances $\gamma(k)$ de la série selon :

$$\gamma(k) = \phi_1 \gamma(k-1) + \phi_2 \gamma(k-2) + \dots + \phi_p \gamma(k-p), \quad k = 1, \dots, p.$$

Ces équations peuvent être mises sous forme matricielle, ce qui facilite leur résolution pour l'estimation des coefficients du modèle AR.

Exemple : Estimation des coefficients d'un processus AR(2) via Yule-Walker Supposons que nous avons une série simulée issue d'un processus AR(2) défini par :

$$y_t = 0.5y_{t-1} - 0.3y_{t-2} + \epsilon_t.$$

Les équations de Yule-Walker permettent d'estimer les coefficients ϕ_1 et ϕ_2 à partir des autocovariances de la série. La Figure 23 présente, sous forme de diagramme en barres, la comparaison entre les coefficients vrais et les coefficients estimés via cette méthode.




Figure 23: Estimation des coefficients d'un processus AR(2) via les équations de Yule-Walker.

7 Méthodologie classique d'Analyse des Séries Temporelles

L'analyse classique des séries temporelles suit une méthodologie rigoureuse pour garantir une modélisation précise et interprétable. Nous présentons ici les étapes essentielles à suivre.

7.1 Étape 1: Comprendre et Visualiser les Données

Objectif: Identifier les motifs visibles et anomalies.

- **Tracer la série temporelle:** Observer la tendance, la saisonnalité et les fluctuations.
- **Histogramme et boîte à moustaches:** Analyser la distribution des valeurs.
- **Diagramme d'autocorrélation (ACF/PACF):** Détecter des corrélations entre observations successives.

7.2 Étape 2: Analyser la Stationnarité

Objectif: Vérifier si la série a des propriétés statistiques constantes dans le temps.

- Tests de stationnarité:
 - Test de Dickey-Fuller Augmenté (ADF)
 - Test de KPSS
- Transformations possibles:
 - Différenciation: $\Delta y_t = y_t - y_{t-1}$ si la série présente une tendance.
 - Transformation logarithmique: si l'amplitude des variations évolue avec le temps.

7.3 Étape 3: Décomposer la Série Temporelle

Objectif: Séparer les composantes fondamentales (tendance, saisonnalité, bruit).

- **Décomposition additive:** $y_t = T_t + S_t + R_t$
- **Décomposition multiplicative:** $y_t = T_t \times S_t \times R_t$

Outils:

- `statsmodels.tsa.seasonal_decompose()`
- STL (Seasonal-Trend-Loess) pour une meilleure flexibilité.

7.4 Étape 4: Modélisation et Prédiction

Objectif: Choisir un modèle adapté à la série temporelle.

- **Si la série est stationnaire:** Modèles ARMA, AR, MA.
- **Si la série n'est pas stationnaire:** ARIMA ou différenciation avant ARMA.
- **Si la série est saisonnière:** SARIMA (ajoute une composante saisonnière).
- **Si la variance est instable:** Modèle GARCH (très utilisé en finance).

Critères de choix des paramètres du modèle:

- Autocorrélation (ACF) et Autocorrélation Partielle (PACF).
- Critères d'information: AIC, BIC.

7.5 Étape 5: Évaluation et Validation du Modèle

Objectif: Vérifier la qualité du modèle avant de l'utiliser.


- **Analyse des résidus:** doivent suivre un bruit blanc.
- **Métriques d'évaluation:**
 - MSE (Mean Squared Error)
 - RMSE (Root Mean Squared Error)
 - MAE (Mean Absolute Error)
- **Validation croisée:** test sur des fenêtres temporelles (walk-forward validation).

7.6 Étape 6: Prédiction et Interprétation


Objectif: Prédire les valeurs futures et interpréter les résultats.

- **Faire des prévisions** avec intervalles de confiance.
- **Interpréter les résultats** pour la prise de décision (ex. anticipation de la demande, gestion des stocks, analyse des risques).

8 Pipeline d'Analyse d'une Série Temporelle



Détail de l'Étape 1 : Observation

• **Visualisation :**

- Tracez la série temporelle (courbes, scatter plots, etc.) afin de repérer tendances, cycles et anomalies.


• **Statistiques descriptives :**

- Calculez la moyenne, la médiane, l'écart-type, la variance, le minimum et le maximum.

• **Analyse de la distribution :**

- Utilisez des histogrammes et des boxplots pour étudier la répartition des valeurs.

Détail de l'Étape 2 : Analyse de Stationnarité



- **Objectif de l'analyse de stationnarité :**

- Vérifier que la série ne présente pas de tendance ni de variation de variance significative au fil du temps, ce qui est requis pour certains modèles.


- **Tests statistiques :**

- Réalisez le test d'Augmented Dickey-Fuller (ADF) pour détecter une racine unitaire.
- Complétez avec le test KPSS ou le test Phillips-Perron (PP) pour confirmer la présence ou l'absence de stationnarité.

- **Transformations éventuelles :**

- Si la série n'est pas stationnaire, appliquez une différenciation afin d'éliminer la tendance.
- Une transformation logarithmique peut être utilisée pour stabiliser la variance.

Détail de l'Étape 3 : Structure Temporelle


• **Graphiques ACF et PACF :**

- Tracez les courbes d'autocorrélation (ACF) et d'autocorrélation partielle (PACF) pour identifier les dépendances temporelles.

• **Décomposition de la série :**

- Décomposez la série en ses composantes (tendance, saisonnalité, résidus) pour mieux comprendre sa structure.

Détail de l'Étape 4 : Modélisation

• **Choix du modèle :**

- Pour une série stationnaire, envisagez des modèles AR, MA ou ARMA.
- Pour une série non stationnaire, optez pour un modèle ARIMA.
- Pour les données saisonnières, utilisez SARIMA ou SARIMAX.


• **Sélection des paramètres :**

- Utilisez les graphiques ACF/PACF et des critères d'information (AIC, BIC) pour déterminer les ordres p , d et q .

• **Entraînement :**

- Ajustez le modèle sur l'ensemble des données historiques.

Détail de l'Étape 5 : Validation


• **Évaluation des performances :**

- Utilisez des métriques comme MAE, RMSE et MAPE pour mesurer la qualité des prévisions.

• **Analyse des résidus :**

- Vérifiez que les résidus ne présentent pas d'autocorrélation (ACF des résidus).
- Assurez-vous qu'ils se comportent comme un bruit blanc.

Détail de l'Étape 6 : Prédiction Futures

• **Prévision :**

- Utilisez le modèle ajusté pour prédire les valeurs futures de la série.


• **Intervalle de confiance :**

- Fournissez des intervalles de confiance afin de quantifier l'incertitude.

• **Visualisation :**

- Superposez les prévisions sur la série historique pour faciliter l'interprétation.

Détail de l'Étape 7 : Diagnostic et Amélioration


• **Analyse des résidus :**

- Vérifiez que les résidus ne présentent pas d'autocorrélation.
- Ils doivent se comporter comme un bruit blanc.

• **Diagnostic :**

- Si le modèle présente des lacunes, réévaluez la stationnarité, la structure ou le choix des paramètres.
- Envisagez d'ajuster le modèle ou de tester d'autres approches.

Détail de l'Étape 8 : Rapport et Interprétation

• **Documentation :**

- Rédigez un rapport détaillé qui résume l'ensemble de la démarche, les tests effectués, le modèle choisi et les résultats obtenus.

• **Communication :**

- Présentez les conclusions et discutez des implications des prévisions pour la prise de décision.

9 Mise en pratique du pipeline

Dans cette section, nous allons mettre en œuvre le pipeline d'analyse d'une série temporelle à travers plusieurs exemples pédagogiques. Chaque exemple illustre une situation de complexité croissante, allant de séries synthétiques simples aux séries réelles complexes. Vous serez ensuite invités à reproduire ces analyses sur Google Colab à l'aide de notebooks Python (ou R).

Exemples d'application

1. **Exemple 1: Série simple avec tendance linéaire** *Données simulées:*

$$y_t = 5 + 0.5t + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, 1).$$

Objectifs :

- Visualiser la série et repérer la tendance linéaire.
- Tester la stationnarité et, si nécessaire, appliquer une différenciation.
- Ajuster un modèle ARIMA (par exemple, ARIMA(0,1,0)).

2. **Exemple 2: Série synthétique avec tendance et saisonnalité** *Données simulées:*

$$y_t = 10 + 0.2t + 3 \sin\left(\frac{2\pi t}{12}\right) + \varepsilon_t.$$

Objectifs :

- Identifier la tendance et la composante saisonnière.
- Décomposer la série (tendance, saisonnalité, résidus).
- Ajuster un modèle SARIMA adapté (ex. SARIMA(0,1,1)(0,1,1)[12]).

3. **Exemple 3: Série réelle AirPassengers** *Jeu de données: AirPassengers (données mensuelles).* **Objectifs:**

- Visualiser la série et observer l'augmentation de la variance.
- Appliquer une transformation logarithmique pour stabiliser la variance.
- Tester la stationnarité, décomposer la série, et ajuster un modèle ARIMA/SARIMA.
- Convertir les prévisions à l'échelle d'origine (via l'exponentiation).

4. **Exemple 4: Série complexe avec anomalies et ruptures structurelles** *Données: Une série réelle ou simulée présentant des anomalies (valeurs aberrantes) et des ruptures de tendance.* **Objectifs:**

- Détecter et traiter les anomalies.
- Ajuster le modèle en tenant compte des ruptures structurelles.
- Comparer les prévisions avant et après traitement des anomalies.

5. **Exemple 5 (optionnel): Série multivariée avec variables exogènes** *Données: Une série influencée par d'autres variables (par exemple, la consommation d'énergie en fonction de la température).* **Objectifs:**

- Intégrer des variables exogènes dans le modèle (par exemple, avec un modèle SARIMAX).
- Comparer les performances du modèle avec et sans variables exogènes.

Instructions pour les étudiants:

Vous êtes invités à réaliser ces exemples sur Google Colab. Pour chaque exemple, créez un notebook Python (ou R) qui inclut :

- Le code de génération ou de chargement des données.
- La visualisation de la série temporelle.
- La réalisation des tests de stationnarité et les transformations éventuelles.
- La décomposition de la série (si applicable).
- L'ajustement du modèle approprié (ARIMA, SARIMA, SARIMAX, etc.).
- La production et la visualisation des prévisions, avec les intervalles de confiance.

Chaque notebook devra comporter des commentaires explicatifs afin de décrire la démarche et l'interprétation des résultats. Cela permettra de mettre en pratique le pipeline vu en cours, du plus simple au plus complexe.

10 Exercice: Analyse Complète d'une Série Temporelle et Prévision

Objectif : Cet exercice a pour but de vous faire appliquer la méthodologie classique d'analyse des séries temporelles. Vous allez :

1. Charger et visualiser une série temporelle synthétique présentant une tendance, une saisonnalité et du bruit.
2. Analyser la stationnarité de la série à l'aide de tests statistiques (ADF et KPSS) et appliquer, si nécessaire, une transformation (par exemple, la différenciation).
3. Décomposer la série pour identifier ses composantes fondamentales (tendance, saisonnalité, résidus).
4. Identifier et estimer un modèle (par exemple, ARIMA) en vous aidant des diagrammes d'autocorrélation (ACF) et d'autocorrélation partielle (PACF).
5. Réaliser une prévision sur un horizon donné (par exemple, 12 périodes) et afficher les intervalles de confiance.

Instructions pour Colab :

- Copiez le code ci-dessous dans un notebook Google Colab.
- Exécutez chaque cellule et observez les graphiques générés.
- Commentez vos observations et rédigez un court rapport expliquant chacune des étapes et les choix effectués.

Code de Base pour la Version Étudiants :

```
# Importer les librairies nécessaires
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
from statsmodels.tsa.seasonal import seasonal_decompose
from statsmodels.tsa.stattools import adfuller, kpss
from statsmodels.tsa.arima.model import ARIMA

# Générer une série temporelle synthétique
np.random.seed(42)
date_range = pd.date_range(start="2010-01-01", periods=120, freq="M") # 10 ans de
trend = np.linspace(50, 100, 120) # Tendance linéaire
seasonality = 10 * np.sin(2 * np.pi * np.arange(120) / 12) # Saisonnalité annuelle
noise = np.random.normal(0, 5, 120) # Bruit aléatoire
data = trend + seasonality + noise
ts = pd.Series(data, index=date_range)
```

```
# Visualisation de la série
plt.figure(figsize=(12, 6))
plt.plot(ts, label="Série Temporelle")
plt.title("Série Temporelle Synthétique")
plt.xlabel("Date")
plt.ylabel("Valeur")
plt.legend()
plt.grid(True)
plt.show()

# Visualisation de la distribution (Histogramme)
plt.figure(figsize=(10, 4))
plt.hist(ts, bins=20, color='skyblue', edgecolor='black')
plt.title("Histogramme de la Série")
plt.xlabel("Valeur")
plt.ylabel("Fréquence")
plt.show()

# Tests de stationnarité
result_adf = adfuller(ts)
print("Test ADF:")
print(f"Statistic: {result_adf[0]:.4f}")
print(f"P-value: {result_adf[1]:.4f}")

result_kpss = kpss(ts, regression='c', nlags="auto")
print("\nTest KPSS:")
print(f"Statistic: {result_kpss[0]:.4f}")
print(f"P-value: {result_kpss[1]:.4f}")

# Si la série n'est pas stationnaire, appliquer une différenciation (d=1)
ts_diff = ts.diff().dropna()
plt.figure(figsize=(12, 6))
plt.plot(ts_diff, label="Série Différenciée (d=1)", color='orange')
plt.title("Série Différenciée")
plt.xlabel("Date")
plt.ylabel("Différence")
plt.legend()
plt.grid(True)
plt.show()

# Décomposition de la série (méthode additive)
result = seasonal_decompose(ts, model='additive', period=12)
result.plot()
plt.tight_layout()
plt.show()

# Diagrammes ACF et PACF pour la série différenciée
fig, ax = plt.subplots(2, 1, figsize=(12, 8))
```

```
sm.graphics.tsa.plot_acf(ts_diff, lags=20, ax=ax[0])
ax[0].set_title("ACF de la Série Différenciée")
sm.graphics.tsa.plot_pacf(ts_diff, lags=20, ax=ax[1])
ax[1].set_title("PACF de la Série Différenciée")
plt.tight_layout()
plt.show()

# Identification et estimation d'un modèle ARIMA (ex: ARIMA(1,1,1))
model = ARIMA(ts, order=(1,1,1))
model_fit = model.fit()
print(model_fit.summary())

# Prévision sur 12 périodes
forecast_steps = 12
forecast = model_fit.get_forecast(steps=forecast_steps)
forecast_ci = forecast.conf_int()

plt.figure(figsize=(12, 6))
plt.plot(ts, label="Série Observée")
plt.plot(forecast.predicted_mean.index, forecast.predicted_mean, label="Prévisions")
plt.fill_between(forecast_ci.index, forecast_ci.iloc[:, 0], forecast_ci.iloc[:, 1],
                 color='pink', alpha=0.3, label="Intervalle de Confiance")
plt.title("Prévision sur 12 Mois")
plt.xlabel("Date")
plt.ylabel("Valeur")
plt.legend()
plt.grid(True)
plt.show()
```

À rédiger dans votre rapport :

- Présentez et interprétez les résultats des tests de stationnarité.
- Discutez de la décomposition de la série et des caractéristiques observées.
- Expliquez le choix du modèle ARIMA(1,1,1) en vous basant sur l'ACF et la PACF.
- Analysez la qualité des prévisions et les intervalles de confiance.

Corrigé: Analyse Complète d'une Série Temporelle et Préviation

Objectif : Ce corrigé présente une solution complète pour l'exercice d'analyse d'une série temporelle synthétique, depuis l'importation des données jusqu'à la prévision. Il démontre la démarche classique de visualisation, de test de stationnarité, de décomposition, d'identification du modèle et de forecasting.

Code Corrigé:

```
# Importer les librairies nécessaires
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
from statsmodels.tsa.seasonal import seasonal_decompose
from statsmodels.tsa.stattools import adfuller, kpss
from statsmodels.tsa.arima.model import ARIMA

# Générer une série temporelle synthétique réaliste
np.random.seed(42)
date_range = pd.date_range(start="2010-01-01", periods=120, freq="M")
trend = np.linspace(50, 100, 120) # Tendance linéaire
seasonality = 10 * np.sin(2 * np.pi * np.arange(120) / 12) # Saisonnalité annuelle
noise = np.random.normal(0, 5, 120) # Bruit aléatoire
data = trend + seasonality + noise
ts = pd.Series(data, index=date_range)

# Visualiser la série temporelle
plt.figure(figsize=(12, 6))
plt.plot(ts, label="Série Temporelle")
plt.title("Série Temporelle Synthétique")
plt.xlabel("Date")
plt.ylabel("Valeur")
plt.legend()
plt.grid(True)
plt.savefig("time_series.png")
plt.show()

# Histogramme pour observer la distribution
plt.figure(figsize=(10, 4))
plt.hist(ts, bins=20, color='skyblue', edgecolor='black')
plt.title("Histogramme de la Série")
plt.xlabel("Valeur")
plt.ylabel("Fréquence")
plt.savefig("histogram.png")
plt.show()
```

```
# Tests de stationnarité
result_adf = adfuller(ts)
print("Test ADF:")
print(f"Statistic: {result_adf[0]:.4f}")
print(f"P-value: {result_adf[1]:.4f}")

result_kpss = kpss(ts, regression='c', nlags="auto")
print("\nTest KPSS:")
print(f"Statistic: {result_kpss[0]:.4f}")
print(f"P-value: {result_kpss[1]:.4f}")

# La série n'est pas stationnaire : application d'une différenciation (d=1)
ts_diff = ts.diff().dropna()
plt.figure(figsize=(12, 6))
plt.plot(ts_diff, label="Série Différenciée (d=1)", color='orange')
plt.title("Série Différenciée")
plt.xlabel("Date")
plt.ylabel("Différence")
plt.legend()
plt.grid(True)
plt.savefig("differenced_series.png")
plt.show()

# Décomposition de la série (modèle additif)
result = seasonal_decompose(ts, model='additive', period=12)
result.plot()
plt.tight_layout()
plt.savefig("decomposition.png")
plt.show()

# Diagrammes ACF et PACF pour la série différenciée
fig, ax = plt.subplots(2, 1, figsize=(12, 8))
sm.graphics.tsa.plot_acf(ts_diff, lags=20, ax=ax[0])
ax[0].set_title("ACF de la Série Différenciée")
sm.graphics.tsa.plot_pacf(ts_diff, lags=20, ax=ax[1])
ax[1].set_title("PACF de la Série Différenciée")
plt.tight_layout()
plt.savefig("acf_pacf.png")
plt.show()

# Identification et estimation du modèle ARIMA
model = ARIMA(ts, order=(1,1,1))
model_fit = model.fit()
print(model_fit.summary())

# Prédiction sur 12 périodes
forecast_steps = 12
forecast = model_fit.get_forecast(steps=forecast_steps)
```

```
forecast_ci = forecast.conf_int()

plt.figure(figsize=(12, 6))
plt.plot(ts, label="Série Observée")
plt.plot(forecast.predicted_mean.index, forecast.predicted_mean, label="Prévisions")
plt.fill_between(forecast_ci.index, forecast_ci.iloc[:, 0], forecast_ci.iloc[:, 1],
                 color='pink', alpha=0.3, label="Intervalle de Confiance")
plt.title("Prévision sur 12 Mois")
plt.xlabel("Date")
plt.ylabel("Valeur")
plt.legend()
plt.grid(True)
plt.savefig("forecast.png")
plt.show()
```

Commentaires et Interprétations :

- Les tests de stationnarité montrent que la série initiale n'est pas stationnaire (p-values supérieures aux seuils critiques), ce qui justifie l'application d'une différenciation.
- La décomposition révèle une tendance ascendante et une saisonnalité annuelle régulière.
- Les diagrammes ACF et PACF de la série différenciée indiquent qu'un modèle ARIMA(1,1,1) est approprié.
- L'estimation du modèle ARIMA fournit des coefficients significatifs et des résidus ressemblant à un bruit blanc, validant ainsi le modèle.
- Les prévisions sur 12 mois montrent une continuation de la tendance observée avec des intervalles de confiance qui augmentent avec l'horizon.

Instructions complémentaires pour l'enseignant :

- Demandez aux étudiants de justifier leur choix de transformation et de modèle.
- Vérifiez que les étudiants comprennent comment interpréter les graphiques et les tests statistiques.
- Encouragez une discussion sur les limites du modèle ARIMA et sur les pistes d'amélioration (ex. validation croisée, modèles hybrides, etc.).

11 Mise en pratique

11.1 Exercice 1: Analyse Simplifiée d'une Série Temporelle

11.1.1 Partie 1 de l'exercice 1

Nous disposons d'une série temporelle représentant les ventes mensuelles d'un produit sur plusieurs années. Nous supposons que les ventes suivent une tendance linéaire simple:

$$y_t = \beta_0 + \beta_1 t + \epsilon_t, \quad (28)$$

avec:

- β_0 : intercept,
- β_1 : coefficient de tendance,
- ϵ_t : bruit aléatoire.

Objectifs:

- Visualiser la série temporelle,
- Identifier la tendance,
- Tester la stationnarité.


11.1.2 Correction - Partie 1

Génération des Données La série temporelle est simulée selon l'équation suivante:

$$y_t = 5 + 0.2t + \epsilon_t, \quad (29)$$

avec $t = \{1, 2, \dots, 100\}$ et $\epsilon_t \sim \mathcal{N}(0, 1)$. Ici, ϵ_t est un bruit gaussien de moyenne nulle et de variance 1.

Visualisation de la Série Temporelle Le graphique trace les valeurs de y_t en fonction de t :



- La tendance linéaire est visible (croissance continue des ventes).
- Les fluctuations autour de cette tendance sont dues au bruit aléatoire ϵ_t .

Test de Stationnarité Hypothèses du Test ADF (Augmented Dickey-Fuller) Le test ADF est une méthode statistique permettant de vérifier la stationnarité d'une série temporelle. Il repose sur les hypothèses suivantes:

- H_0 : La série temporelle possède une racine unitaire, ce qui signifie qu'elle est non stationnaire.
- H_1 : La série temporelle est stationnaire.

Formulation Mathématique Le test ADF repose sur l'estimation de l'équation suivante:

$$\Delta y_t = \phi y_{t-1} + \gamma_1 \Delta y_{t-1} + \dots + \gamma_k \Delta y_{t-k} + \epsilon_t, \quad (30)$$

où:

- $\Delta y_t = y_t - y_{t-1}$ est la différence première de la série temporelle.
- ϕ est le coefficient clé permettant de tester la présence d'une racine unitaire.
- γ_i sont les coefficients des termes de différenciation additionnels (pour ajuster l'autocorrélation).
- ϵ_t représente le bruit aléatoire.

La statistique du test ADF est calculée comme suit:

$$ADF = \frac{\hat{\phi}}{SE(\hat{\phi})}, \quad (31)$$

où:

- $\hat{\phi}$ est l'estimation du coefficient ϕ .
- $SE(\hat{\phi})$ est l'erreur standard associée à $\hat{\phi}$.

Interprétation des Résultats Pour interpréter le résultat du test ADF:

- Si la statistique ADF est inférieure à une valeur critique (1%, 5% ou 10%), on rejette H_0 et on conclut que la série est stationnaire.
- Si la p -valeur associée est inférieure à 0.05, on rejette également H_0 et on conclut que la série est stationnaire.

Résultats pour la Série Originale Pour la série temporelle originale simulée dans cet exercice, les résultats du test ADF sont:

- Statistique ADF = 0.3353.
- p -value = 0.9789.
- Nombre de lags inclus: 6.
- Nombre d'observations utilisées: 93.
- Valeurs critiques:
 - 1%: -3.5027,
 - 5%: -2.8932,
 - 10%: -2.5836.

Conclusion: La p -valeur est largement supérieure à 0.05, et la statistique ADF est supérieure aux valeurs critiques. Par conséquent, nous ne pouvons pas rejeter l'hypothèse nulle H_0 . La série originale est donc non stationnaire.

Différenciation et Stationnarité Pour transformer la série en une série stationnaire, nous appliquons une différenciation de premier ordre:

$$\Delta y_t = y_t - y_{t-1}. \quad (32)$$

Cette opération élimine la tendance linéaire présente dans la série.

Résultats pour la Série Différenciée Après différenciation, le test ADF est de nouveau appliqué, et les résultats sont les suivants:

- Statistique ADF = -7.6334.
- p -value = 0.0000.
- Nombre de lags inclus: 5.
- Nombre d'observations utilisées: 93.
- Valeurs critiques:

- 1%: -3.5027 ,
- 5%: -2.8932 ,
- 10%: -2.5836 .

Conclusion: La p -valeur est inférieure à 0.05, et la statistique ADF est inférieure aux valeurs critiques. Nous rejetons donc l'hypothèse nulle H_0 , ce qui indique que la série différenciée est stationnaire.

Résumé

- La série originale est non stationnaire en raison de la présence d'une tendance linéaire.
- Une simple différenciation permet de rendre la série stationnaire, condition nécessaire pour l'application de nombreux modèles prédictifs comme ARIMA.

Différenciation de la Série Temporelle Pour rendre la série stationnaire, nous appliquons la différenciation:

$$\Delta y_t = y_t - y_{t-1}. \quad (33)$$

Cela élimine la tendance linéaire.

Test ADF: Série Différenciée Pour la série différenciée:

- Statistique ADF = -7.6334 .
- p -value = 0.0000.
- Nombre de lags: 5.
- Nombre d'observations utilisées: 93.
- Valeurs critiques:
 - 1%: -3.5027 ,
 - 5%: -2.8932 ,
 - 10%: -2.5836 .
- Conclusion: Avec p -value < 0.05 , nous rejetons H_0 . La série est stationnaire.

Interprétation

- La série originale n'était pas stationnaire à cause de la tendance linéaire.
- Après différenciation, la série est stationnaire, permettant l'application de modèles comme ARIMA.

12 Exemple complet : Série stationnaire modélisée par ARMA




Figure 24: Représentation de la série temporelle réelle et approximée avec le modèle ARMA. La première sous-figure illustre la série réelle et son approximation. La deuxième montre les résidus entre la série réelle et le modèle, tandis que la troisième visualise la distribution des résidus pour analyser leur comportement.

```

--- Résultats des tests de stationnarité ---
Test ADF (p-value) : 0.0002 (Stationnaire)
Test KPSS (statistique) : 0.2696, p-value : 0.1000 (Stationnaire)

```

Figure 25: Résultats des tests de stationnarité appliqués à la série temporelle. Le Test ADF confirme que la série est stationnaire avec une p-value de 0.0002. Le Test KPSS confirme également la stationnarité avec une statistique de 0.2696 et une p-value de 0.1000.

Cet exemple illustre une série temporelle stationnaire simulée, suivie de tests de stationnarité, d'un ajustement par un modèle ARMA, et de l'analyse des résidus.

1. Génération de la série stationnaire La série est générée à l'aide d'un processus ARMA(1,1), défini par :

$$y_t = -0.5y_{t-1} + \epsilon_t + 0.4\epsilon_{t-1},$$

où $\epsilon_t \sim \mathcal{N}(0, 1)$.

2. Tests de stationnarité Deux tests ont été effectués :

- **Test ADF** : p-value = 0.02 ($p < 0.05$), ce qui indique que la série est stationnaire.
- **Test KPSS** : p-value = 0.08 ($p > 0.05$), ce qui confirme également la stationnarité.

3. Modélisation par ARMA Un modèle ARMA(1,1) a été ajusté pour approximer la série. Les valeurs ajustées ($\hat{y}_t$) suivent la tendance de la série réelle.

4. Analyse des résidus Les résidus ($y_t - \hat{y}_t$) sont :

- Centrés autour de zéro, ce qui indique un bon ajustement.
- Largement distribués de manière normale, conformément aux hypothèses du modèle.

5. Visualisations

- **Figure 1** : La série réelle et son approximation par le modèle ARMA.
- **Figure 2** : Les résidus après ajustement.
- **Figure 3** : La distribution des résidus, qui montre une concentration autour de zéro.

12.1 Exemple : Série temporelle non stationnaire avec saisonnalité

Dans cet exemple, nous analysons une série temporelle non stationnaire présentant une tendance linéaire et une saisonnalité périodique. Nous démontrons les étapes suivantes :

1. Simulation d'une série temporelle non stationnaire.
2. Analyse des propriétés statistiques (espérance, variance).
3. Tests de stationnarité pour vérifier le caractère non stationnaire.
4. Application d'une transformation pour rendre la série stationnaire.
5. Modélisation avec un modèle ARIMA.

Série temporelle simulée La série temporelle est simulée selon l'équation suivante :

$$y_t = \alpha + \beta t + A \sin\left(\frac{2\pi t}{P}\right) + \varepsilon_t,$$

où :

- $\alpha = 10$: Intercepte de la tendance,
- $\beta = 0.1$: Coefficient de la pente,
- $A = 5$: Amplitude de la saisonnalité,
- $P = 12$: Période de la saisonnalité,
- $\varepsilon_t \sim \mathcal{N}(0, 1)$: Bruit gaussien.

Tests de stationnarité Les tests ADF et KPSS sont appliqués à la série originale pour confirmer son caractère non stationnaire. Après différenciation, la série est transformée en une série stationnaire.

Figures Les figures suivantes illustrent les étapes principales :

- Série temporelle originale et série différenciée.
- Résultats des tests de stationnarité.
- Modélisation ARIMA et prédictions.

```
--- Tests de stationnarité sur la série originale ---  
Test ADF (p-value) : 0.9543 (Non stationnaire)  
Test KPSS (statistique) : 2.0497, p-value : 0.0100 (Non stationnaire)  
  
--- Tests de stationnarité sur la série différenciée ---  
Test ADF (p-value) : 0.0000 (Stationnaire)  
Test KPSS (statistique) : 0.0129, p-value : 0.1000 (Stationnaire)
```

Figure 26: Résultats des tests




Figure 27: Part 1 : Série temporelle originale et transformation par différenciation. La série originale présente une tendance et une saisonnalité visibles, confirmées par les tests de stationnarité. La série différenciée montre une variabilité stationnaire.- Part 2: Modélisation ARIMA et prédictions. La série réelle et les prédictions montrent une bonne correspondance, avec des résidus proches de 0 et une distribution conforme à une hypothèse de bruit blanc.